TRABAJO TERMINAL I · MECATRÓNICA · UPIITA–IPN

Control de posición de robot manipulador usando redes neuronales cuantizadas

TTM-2025/2-56

Presenta: Ramiro Mendoza Díaz

Asesor: Dr. Jorge Alejandro Juárez Lora

Presidenta: Dra. Blanca Rosa Briseño Tepepa

Secretaria: M. en C. Cecilia Fernández Nava

CONTENIDO

Índice

01 Descripción del problema y objetivos

02 Marco teórico

03 Diseño e implementación

04 Evaluación y resultados

05 Conclusiones y referencias

Descripción del problema

01 La creciente complejidad de las tareas robóticas motiva investigar diferentes métodos de control.

02 La inferencia neuronal requiere cómputo y transferencias entre memoria y procesador, asociadas al cuello de botella de Von Neumann.

03 En plataformas con recursos restringidos, especialmente sistemas móviles alimentados por baterías, el presupuesto de cómputo y energía es limitado.

04 Se estudia la cuantización para reducir los recursos utilizados y evaluar su efecto sobre la precisión del control.

Fuente: motivación y alcance del reporte TT1 [1]

Objetivo general

Evaluar el desempeño energético, de precisión y de recursos utilizados en la implementación de un control de lazo cerrado con una planta robótica con control tradicional y con una red neuronal cuantizada.

Alcance evaluado en TT1: seguimiento, tamaño del archivo y latencia de inferencia en simulación.

Fuente: objetivo declarado en TT1 [1]

Objetivos específicos a cumplir en TT1

01 Investigar redes cuantizadas y metodologías de evaluación.

02 Definir la arquitectura y diseñar el controlador neuronal base.

03 Establecer la metodología de cuantización y comparación.

04 Diseñar el plan experimental y poner en marcha la plataforma.

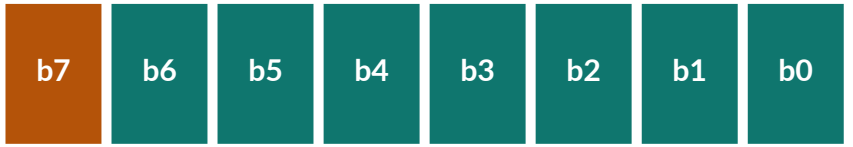
Síntesis de objetivos declarados en TT1 [1]

Marco teórico: FP32 e INT8

FP32 · 32 bits por valor



INT8 · 8 bits por valor



−128 … 127

FP32: 4 bytes por valor
INT8: 1 byte por valor

La cuantización conserva la topología; algunos tensores permanecen flotantes.

Fuentes: IEEE 754 [2]; cuantización ONNX Runtime [3]

Marco teórico: cuantización

$L = 2^B \rightarrow$ 256 códigos para B = 8

$$S = (x_{max} - x_{min}) / (q_{max} - q_{min})$$
$$x_int = clip(round(x/S) + Z, q_{min}, q_{max})$$
$$\hat{x} = S(x_int - Z)$$

S: separación entre niveles
Z: código que representa el cero real
x̂: valor reconstruido

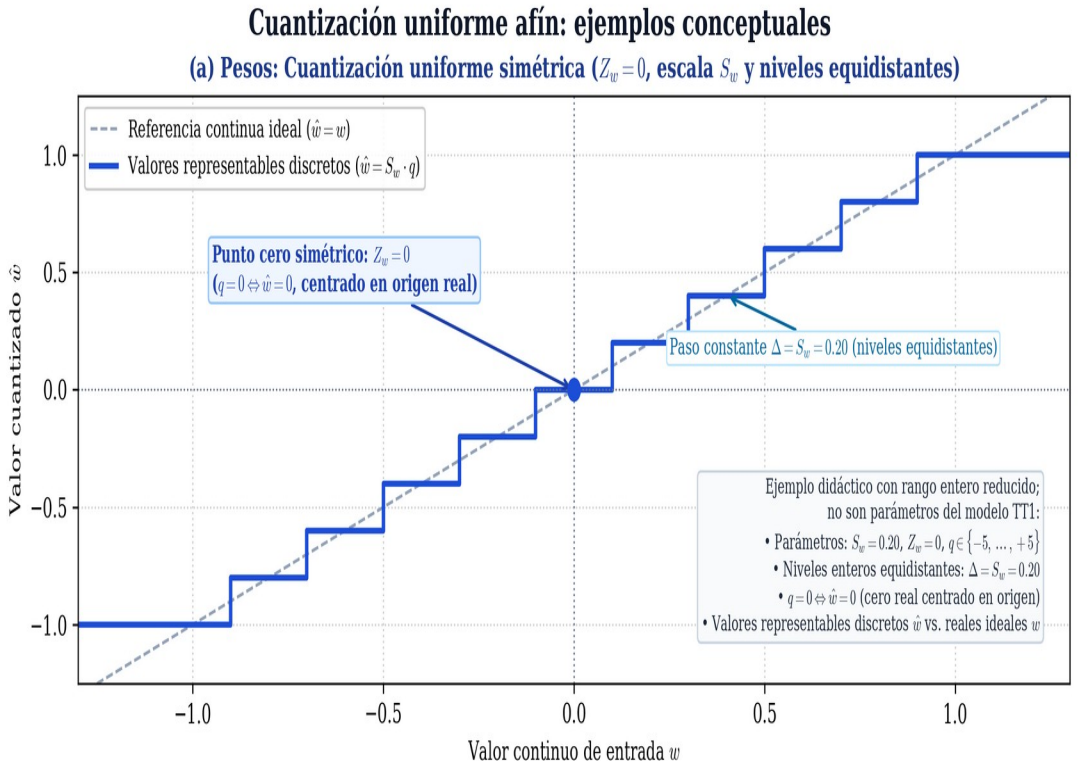
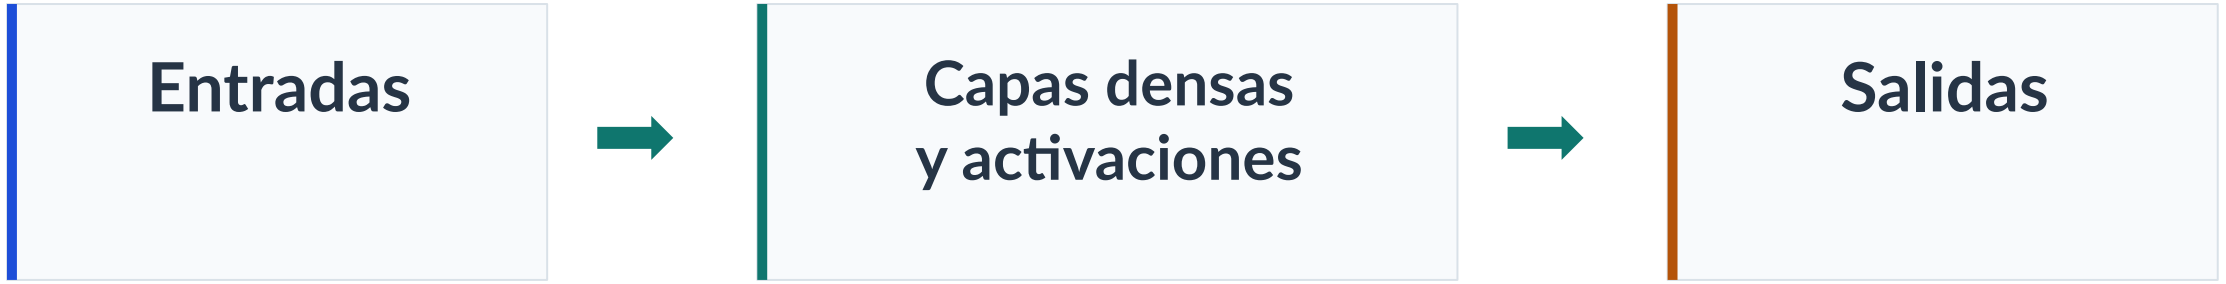


Figura extraída del reporte TT1; ejemplo visual.

Fuentes: cuantización lineal [3]; ilustración conceptual de TT1 [1]

Marco teórico: redes neuronales



Las capas densas combinan las entradas mediante pesos y sesgos.
Las activaciones permiten representar relaciones no lineales.

La cuantización modifica la representación numérica, no el número de neuronas.

Fuentes: capas densas PyTorch [4]; implementación TT1 [1]

Marco teórico: ONNX

01 Modelo descrito mediante un grafo de operadores y tensores.

02 Representación abierta para herramientas compatibles.

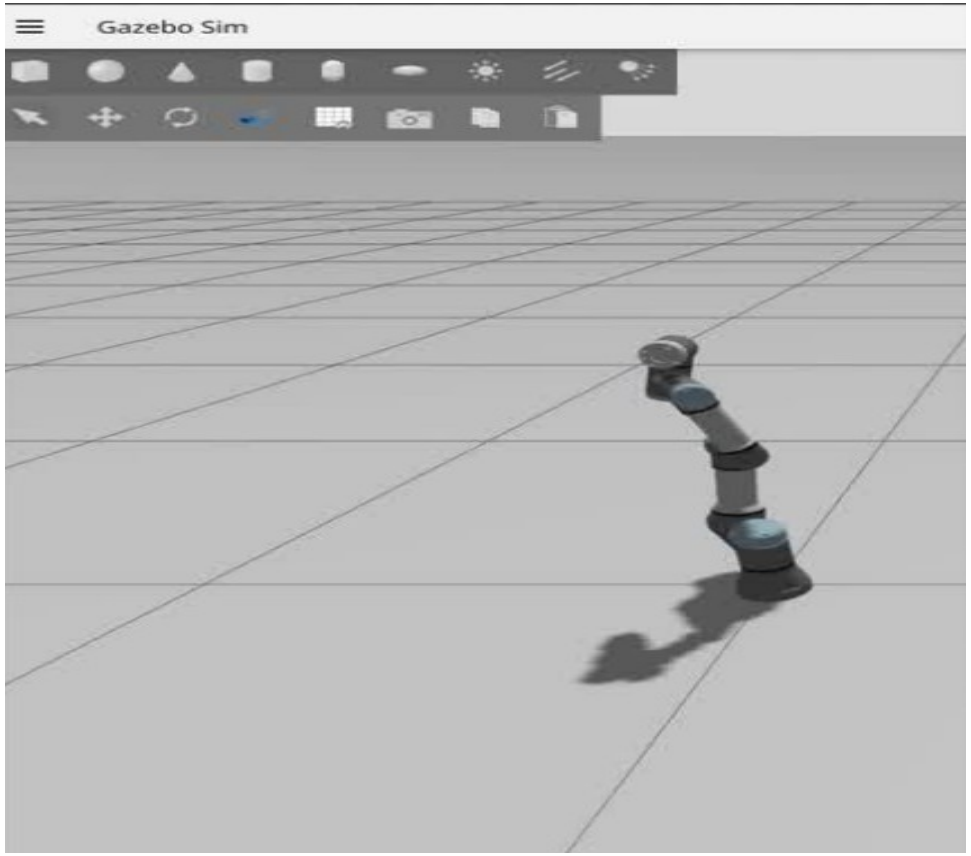
03 En TT1: exportación desde PyTorch e inferencia C++.

ONNX describe el modelo; ONNX Runtime lo ejecuta.

PyTorch → archivo ONNX → ONNX Runtime

Fuente: ONNX Concepts [5]

Entorno de simulación



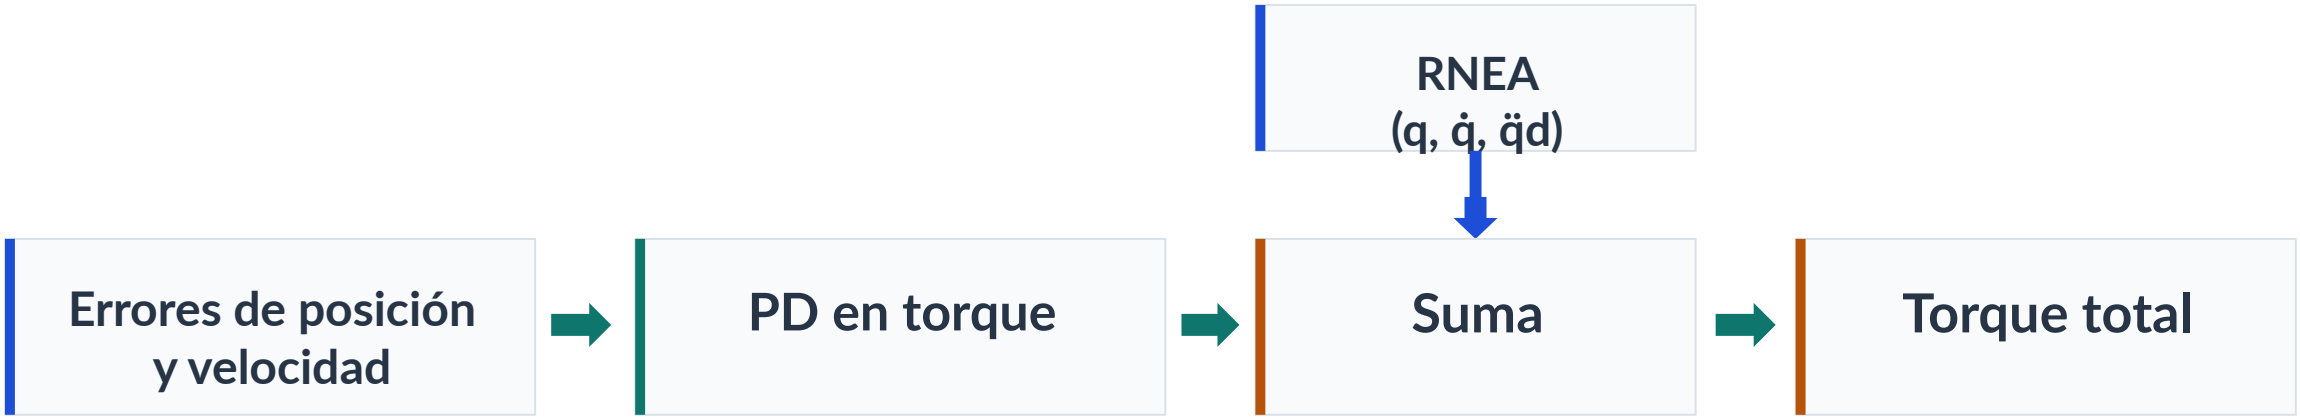
UR3e · 6 grados de libertad
Gazebo Harmonic
ROS 2 Jazzy y ros2_control
Inferencia en CPU

500 Hz: control nominal
100 Hz: referencias y datos

Fuente: captura del avance y reporte TT1 [1]

Control RNEA + PD

$$\tau_{total} = RNEA(q, \dot{q}, \ddot{q}_d) + K_p e + K_d \dot{e}$$



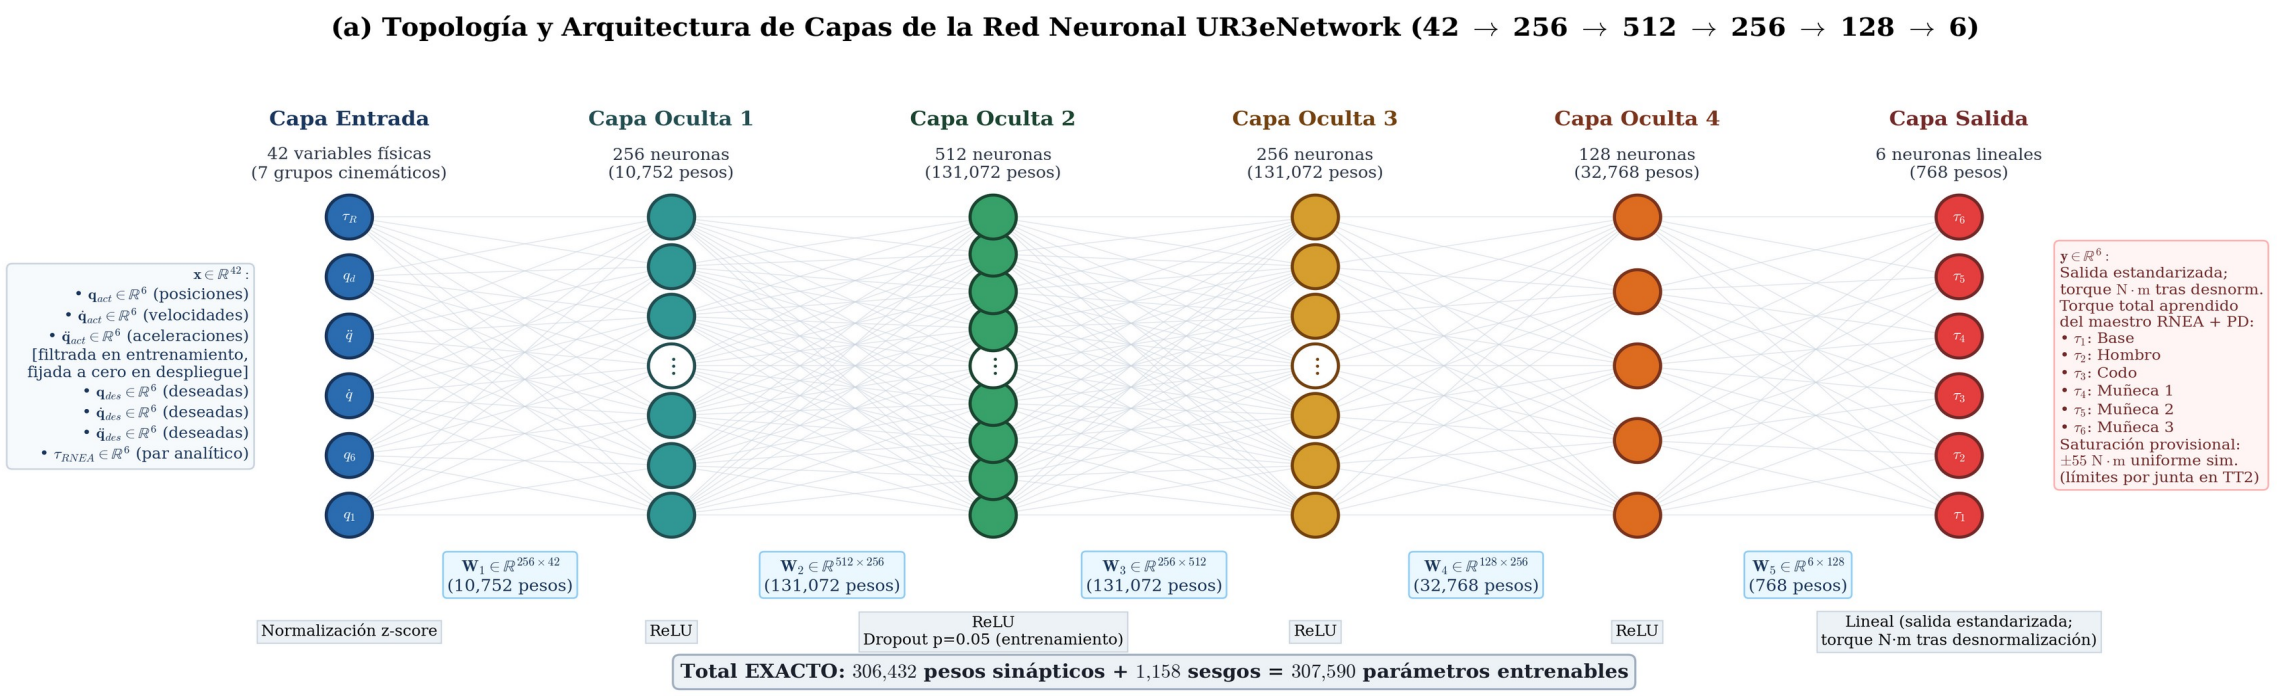
Error de posición: referencia − posición actual.

Error de velocidad: velocidad deseada − velocidad actual.

El torque total se utiliza como objetivo de entrenamiento.

Fuentes: dinámica de manipuladores [6]; controlador TT1 [1]

Topología de la red implementada



42 → 256 → 512 → 256 → 128 → 6

307,590 parámetros entrenables

Fuente: figura corregida y código de TT1 [1]

Control con red neuronal



Las referencias y el estado articular forman las entradas de la red.

Límite uniforme ±55 N·m, provisional en simulación.

Fuente: arquitectura funcional corregida de TT1 [1]

Datos y tratamiento de la aceleración

42 características de entrada → 6 valores de torque objetivo

Estado actual · referencias deseadas · torque RNEA

Entrenamiento
Aceleración actual filtrada

Despliegue
Aceleración actual fijada a cero

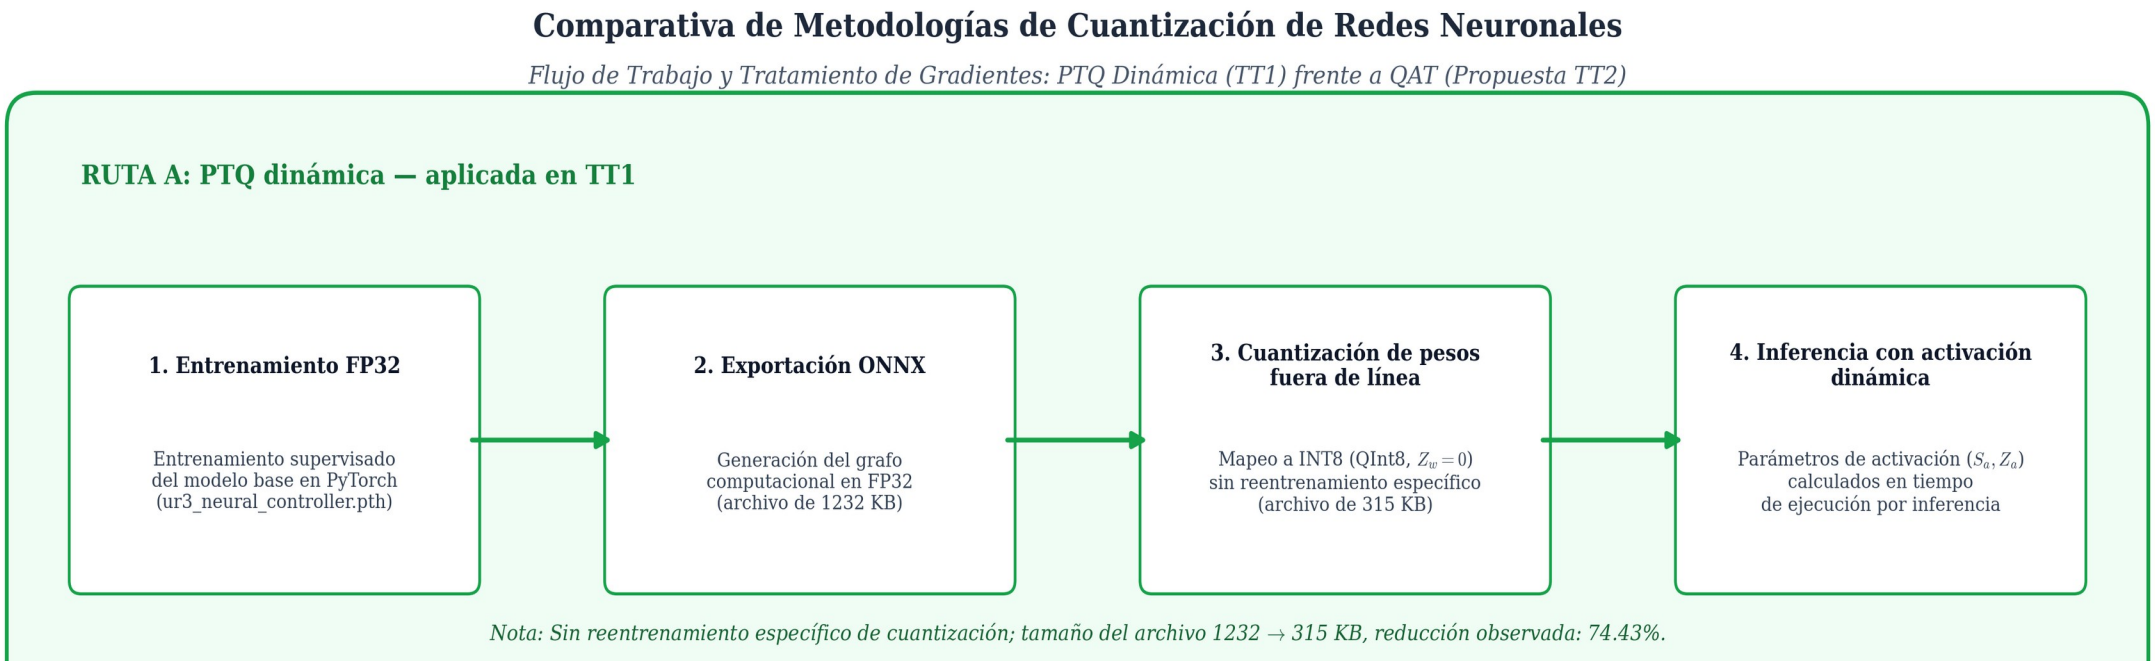
Esta diferencia entre entradas se reconoce como una limitación.

Pendiente: estimar la aceleración con bajo costo computacional
y medir su impacto en el tiempo total del control.

La aceleración deseada se conserva como entrada.

Fuente: pipeline y limitaciones de TT1 [1]

Cuantización dinámica implementada



Pesos: cuantizados después del entrenamiento, fuera de línea.
Activaciones: escala y punto cero calculados durante la inferencia.

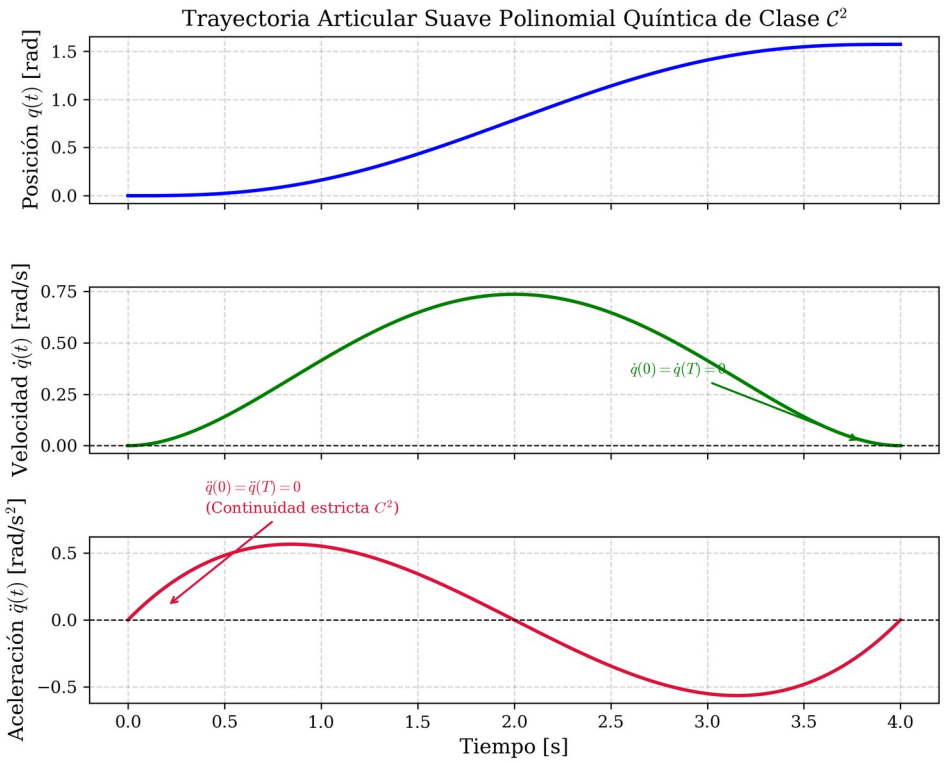
Fuentes: flujo PTQ corregido [1]; ONNX Runtime [3]

Condiciones y métricas de comparación

Tres configuraciones
RNEA + PD · Red FP32 · Red INT8

Trayectorias articulares quínticas
Simulación y ejecución en CPU
Datos recopilados a 100 Hz

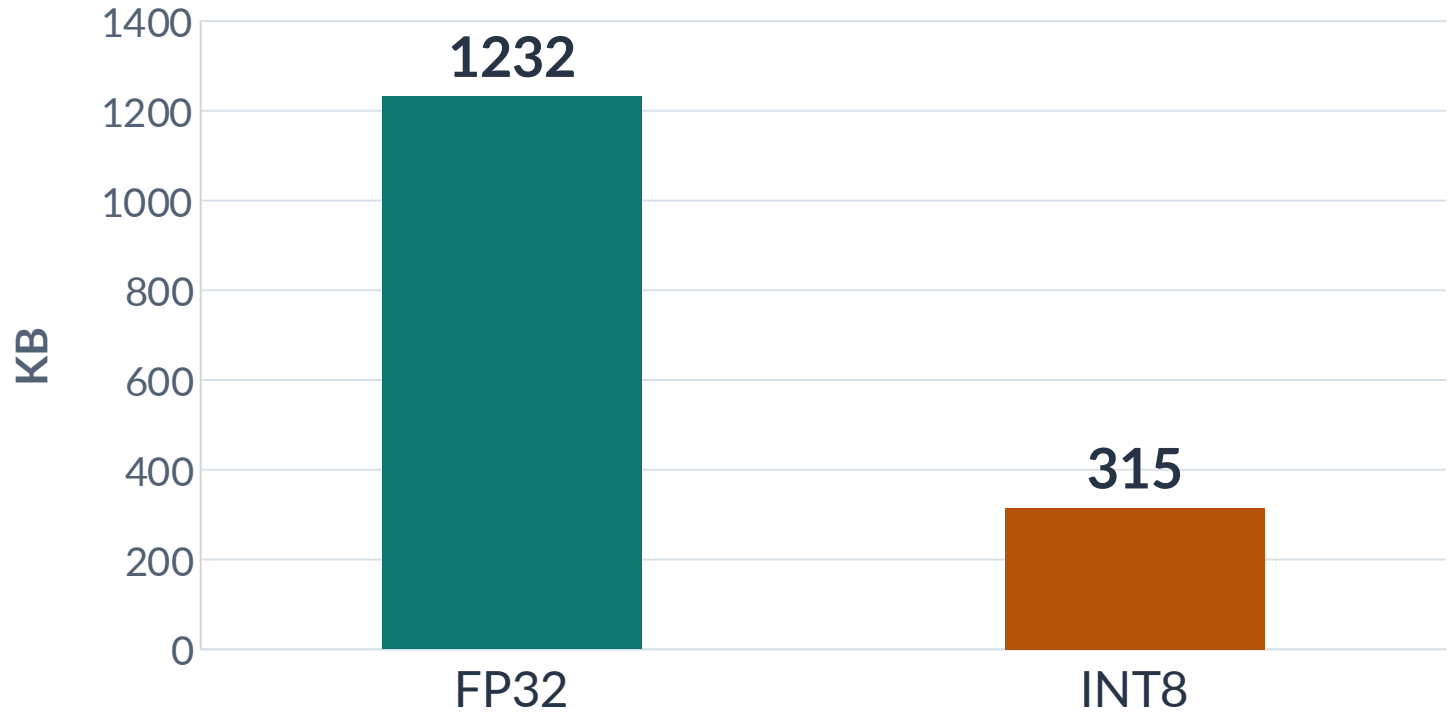
Métricas: RMSE, inferencia
y tamaño del archivo ONNX



Perfil quíntico ilustrativo extraído del reporte;
no es un registro del ensayo.

Fuente: condiciones experimentales y perfil quíntico de TT1 [1]

Tamaño del archivo ONNX



74.43%

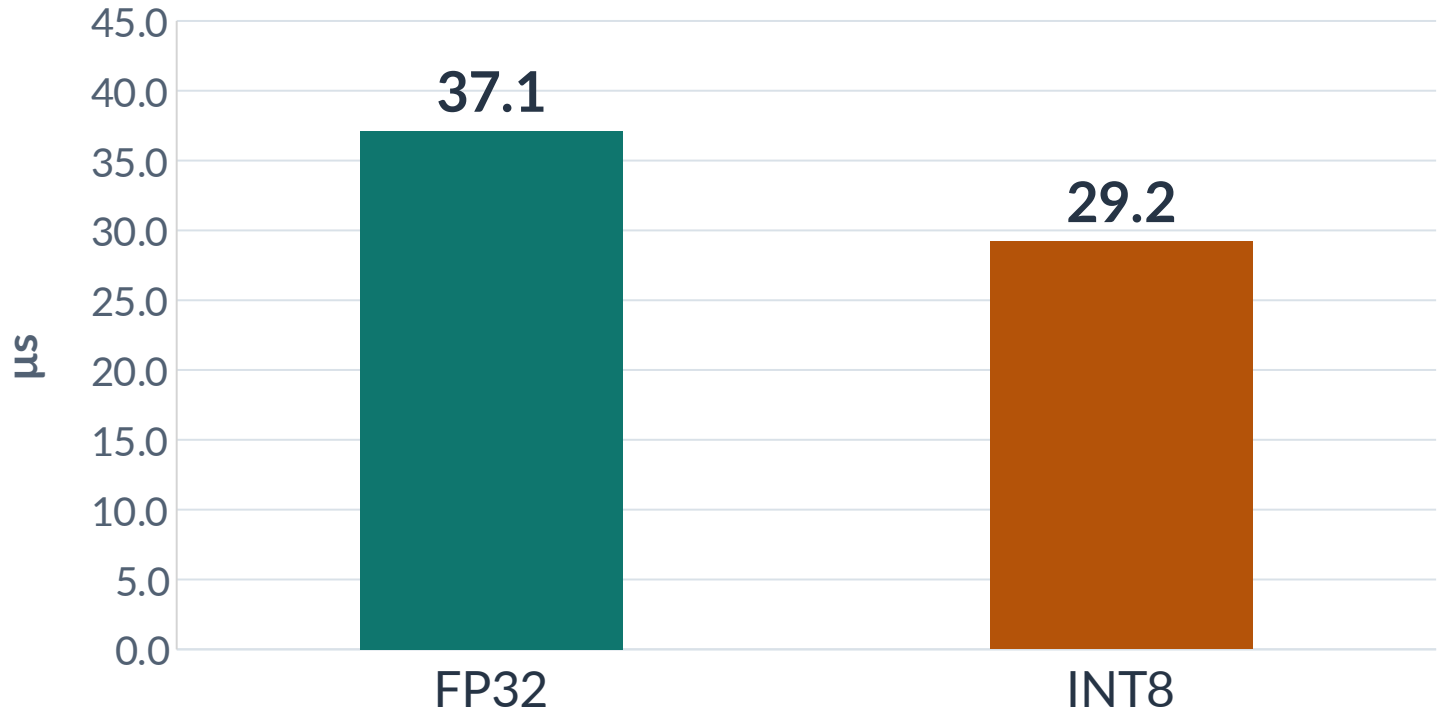
reducción del archivo

Tamaño del archivo en disco; no representa la memoria total de ejecución.

Fuente: tamaños de campaña confirmados en TT1 [1]

RESULTADOS

Latencia media de inferencia



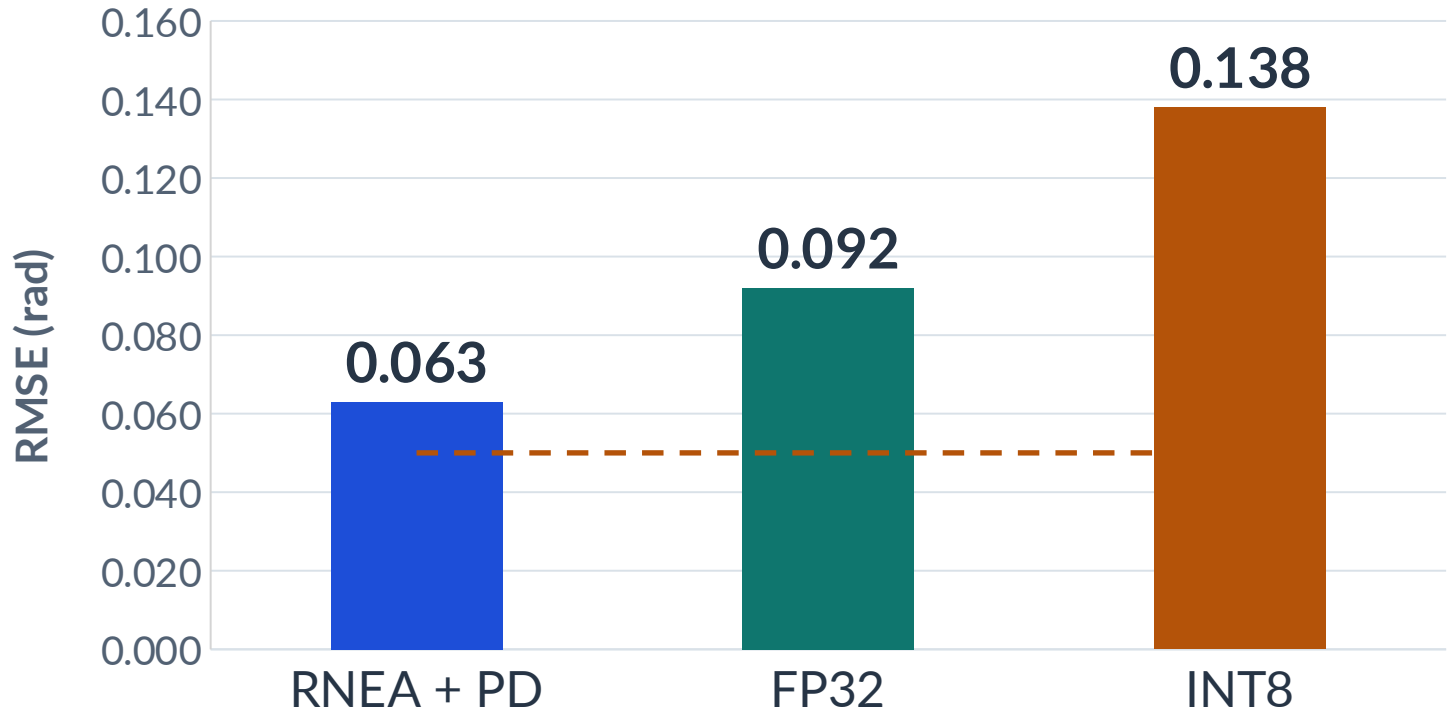
21.29%

reducción de la media

Inferencia aislada en CPU.
El tiempo total del controlador permanece por verificar.

Fuente: medias de inferencia reportadas en TT1 [1]

Seguimiento articular



RF-01

RMSE < 0.05 rad

No alcanzado en las tres configuraciones.

Referencia de desempeño para la siguiente etapa.

Fuente: RMSE reportados y criterio RF-01 en TT1 [1]

Cumplimiento y limitaciones

Criterio	Resultado TT1	Estado
Reducción ONNX ≥50%	74.43%	Cumplido
RMSE <0.05 rad	0.063 / 0.092 / 0.138 rad	No alcanzado
Ciclo total y jitter	Sin medición trazable completa	Por verificar
Consumo eléctrico	Sin medición directa	Pendiente

Saturación uniforme ±55 N·m: simplificación provisional de simulación.

Fuente: matriz consolidada de verificación TT1 [1]

Conclusiones de TT1

01 Se integró y evaluó el control con red neuronal en simulación.

02 INT8 redujo el archivo ONNX y la latencia media de inferencia observada.

03 La precisión de seguimiento no alcanzó RF-01; se documentaron las limitaciones.

Fuente: resultados y limitaciones de TT1 [1]

Referencias

[1] R. Mendoza Díaz. Reporte de Trabajo Terminal I. UPIITA–IPN, 2026.

[2] IEEE. IEEE Standard for Floating-Point Arithmetic, IEEE 754-2019. standards.ieee.org/standard/754-2019.html

[3] ONNX Runtime. Quantize ONNX models. onnxruntime.ai/docs/performance/model-optimizations/quantization.html

[4] PyTorch. torch.nn.Linear. docs.pytorch.org/docs/stable/generated/torch.nn.Linear.html

[5] ONNX. ONNX Concepts. onnx.ai/onnx/intro/concepts.html

[6] J. J. Craig. Introduction to Robotics: Mechanics and Control. 3.ª ed., Pearson Prentice Hall, 2005.