



Instituto Politécnico Nacional

Unidad Profesional Interdisciplinaria en Ingeniería y
Tecnologías Avanzadas

Ingeniería Mecatrónica

Reporte de Trabajo Terminal 1

Control de posición de robot manipulador usando redes neuronales cuantizadas

Autor:

Mendoza Díaz Ramiro

Asesor:

Dr. Jorge Alejandro Juárez Lora

Profesores:

Fernandez Nava Cecilia
Martínez Solis Sandra

Portada con firmas

(Añadir la portada de firmas aquí)

Dedicatoria...

Agradecimientos

Agradezco a...

Índice

Resumen	VI
Abstract	VI
Palabras clave	VII
Índice de figuras	VIII
Índice de tablas	IX
Nomenclatura	X
Simbología	XII
Introducción	1
0.0.1. Multiplicación de matrices, procesamiento de señales y problemas de computación en tareas robóticas	2
0.0.2. Cuello de botella de Von Neumann	2
0.0.3. Proyección a futuro de la problemática energética	3
0.0.4. Objetivo general	4
0.0.5. Objetivos específicos TT1	4
0.0.6. Objetivos específicos TT2	5
0.0.7. Técnicas de control clásico para robots manipuladores	6
0.0.8. Transición hacia el control basado en Inteligencia Artificial (IA)	7
0.0.9. Estado del arte	8
1. Marco de Referencia	9
1.1. Marco teórico	9
1.1.1. Modelado y Control de Robots Manipuladores	9
1.1.2. Redes Neuronales Artificiales para el Control Robótico	12
1.1.3. Estrategias de Optimización de Redes Neuronales	12
1.2. Marco procedimental	17
1.2.1. Metodología mecatrónica	17
2. Diseño del sistema	18
2.1. Diseño conceptual	18
2.1.1. Necesidades - requerimientos	19
2.1.2. Arquitectura funcional (funciones)	19
2.1.3. Arquitectura física (módulos)	22
2.1.4. Propuestas solución	23
2.1.5. Validación	24
2.1.6. Selección diseño conceptual	26
2.2. Diseño detallado	27
2.2.1. Detalle módulo 1 (M_1)	27

2.2.2.	Detalle módulo 2 (M_2)	27
2.2.3.	Detalle módulo n (M_n)	27
2.2.4.	Integración sistema mecatrónico	27
3.	Implementación del sistema	28
3.1.	Implementación módulo 1 (M_1)	28
3.1.1.	Verificación (M_1)	28
3.2.	Implementación módulo 2 (M_2)	28
3.2.1.	Verificación (M_2)	28
3.3.	Implementación módulo n (M_n)	28
3.3.1.	Verificación (M_n)	28
3.4.	Integración del sistema mecatrónico	28
3.4.1.	Verificación del sistema mecatrónico	28
4.	Análisis de resultados	28
4.1.	Análisis de ingeniería	28
4.2.	Análisis de costos	28
4.3.	Análisis de valor	28
	Conclusiones	29
	Recomendaciones y trabajo a futuro	29
	Apéndices	30
	Anexos	30
4.3.1.	Recursos Estimados e Infraestructura	30
4.3.2.	Recursos Humanos	30
4.3.3.	Recursos Materiales y Económicos	30
4.3.4.	Infraestructura Requerida	32
4.3.5.	Planeación de Actividades (Cronograma General)	33
	Fuentes – Referencias	35
	Glosario	38

Resumen

La robótica moderna demanda sistemas de control cada vez más complejos para que los manipuladores ejecuten tareas aún más desarrolladas con precisión y adaptabilidad. Si bien la inteligencia artificial, y en particular las redes neuronales profundas (DNNs), ofrecen soluciones potentes, su elevado costo computacional y energético restringe su aplicación en plataformas robóticas con cómputo al filo. Este proyecto de investigación se centra en este desafío, motivado por la necesidad crítica de desarrollar controladores robóticos energéticamente eficientes y de validar cuantitativamente sus beneficios.

Se plantea el problema de cómo implementar un control de posición para un robot manipulador que sea preciso y, fundamentalmente, de bajo consumo, mediante el uso de redes neuronales cuantizadas (QNNs) desplegadas en hardware reconfigurable (FPGA). El objetivo general de este trabajo es diseñar, implementar y evaluar comparativamente el desempeño energético, la utilización de recursos de hardware y la precisión del control de un sistema basado en QNNs, contrastándolo con un control PID clásico y una red neuronal de punto flotante (FP12-NN), todos operando sobre la misma plataforma FPGA.

La propuesta de solución abarca el desarrollo de estos tres enfoques de control, la aplicación de técnicas de cuantización para generar modelos QNN con distintos niveles de precisión, y la ejecución de un plan experimental para medir y analizar las métricas de rendimiento y consumo energético. Se espera que los resultados demuestren la viabilidad y las ventajas energéticas de las QNNs, aportando una metodología y datos concretos para el diseño de futuros sistemas de control robótico energéticamente sostenibles.

Abstract

Modern robotics demands increasingly complex control systems for manipulators to perform more advanced tasks with precision and adaptability. While artificial intelligence—particularly deep neural networks (DNNs)—offers powerful solutions, their high computational and energy costs limit their use in robotic platforms with edge computing. This research project addresses this challenge, driven by the critical need to develop energy-efficient robotic controllers and to quantitatively validate their benefits.

The central problem is how to implement a position control system for a robotic manipulator that is both accurate and, fundamentally, low-power, using quantized neural networks (QNNs) deployed on reconfigurable hardware (FPGAs). The main objective of this work is to design, implement, and comparatively evaluate the energy performance, hardware resource usage, and control accuracy of a QNN-based system, benchmarking it against a classical PID controller and a floating-point neural network (FP12-NN), all running on the same FPGA platform.

The proposed solution involves developing all three control strategies, applying quantization techniques to produce QNN models with varying precision levels, and executing an experimental plan to measure and analyze performance and energy consumption metrics. The expected outcome is to demonstrate the feasibility and energy advantages of QNNs, providing both a methodology and concrete data for the design of future energy-efficient robotic control systems.

Palabras clave

Redes Neuronales Cuantizadas, Control de Robots, FPGA, Eficiencia Energética, Robótica, Computo al filo.

Índice de figuras

1.	Arquitectura Von Neumann original [1]	2
2.	Reducción de bits de entrada y de precisión en la salida por la cuantización [2]	4
3.	Diagrama simplificado de un control PID [3].	6
4.	Estructura de una red neuronal (ANN) [4].	7
5.	Comparación de una ANN y una DNN [5].	8
6.	Diagrama de la arquitectura funcional y flujo de datos en tiempo real del sistema de control inteligente bajo la metodología ágil.	21

Índice de cuadros

1.	Acrónimos y términos técnicos empleados en el proyecto.	X
2.	Simbología matemática y magnitudes físicas del sistema mecatrónico. .	XII
3.	Requerimientos funcionales y no funcionales del sistema de control mecatrónico.	20
4.	Matriz de selección conceptual de Pugh para las alternativas del sistema de control.	26

Nomenclatura

En la Tabla 1 se presentan los acrónimos, términos técnicos y abreviaturas especializadas utilizadas a lo largo de este documento, ordenadas alfabéticamente.

Cuadro 1: Acrónimos y términos técnicos empleados en el proyecto.

Término / Sigla	Significado y Descripción Técnica
AI / IA	Inteligencia Artificial (<i>Artificial Intelligence</i>).
ANN	Red Neuronal Artificial (<i>Artificial Neural Network</i>).
CIM	Computación en Memoria (<i>Computing-In-Memory</i>).
CoM	Centro de Masa (<i>Center of Mass</i>) de un eslabón rígido.
CTC	Control por Par Computado (<i>Computed Torque Control</i>).
DH	Denavit-Hartenberg (convención cinemática modificada de parámetros geométricos).
DNN	Red Neuronal Profunda (<i>Deep Neural Network</i>).
FP32	Formato de punto flotante de precisión simple de 32 bits (estándar IEEE 754).
FPGA	Matriz de Puertas Lógicas Programable en Campo (<i>Field-Programmable Gate Array</i>).
GDL	Grados de Libertad (<i>Degrees of Freedom</i> , DoF).
INT8	Formato numérico entero con signo de 8 bits (rango $[-128, 127]$).
MAC	Operación de Multiplicación y Acumulación (<i>Multiply-Accumulate</i>).
MAE	Error Absoluto Medio (<i>Mean Absolute Error</i>).
MCAP	Formato de almacenamiento eficiente para grabación de datos y telemetría en ROS 2.
ML	Aprendizaje Automático (<i>Machine Learning</i>).
MLP	Perceptrón Multicapa (<i>Multilayer Perceptron</i>).
MSE	Error Cuadrático Medio (<i>Mean Squared Error</i>).
ONNX	Formato Abierto para Intercambio de Redes Neuronales (<i>Open Neural Network Exchange</i>).
PD / PID	Controlador Proporcional-Derivativo / Proporcional-Integral-Derivativo.
PINN	Red Neuronal Informada por la Física (<i>Physics-Informed Neural Network</i>).
PTQ	Cuantización Post-Entrenamiento (<i>Post-Training Quantization</i>).
QAT	Entrenamiento Consciente de Cuantización (<i>Quantization-Aware Training</i>).
QNN	Red Neuronal Cuantizada (<i>Quantized Neural Network</i>).

Continúa en la siguiente página...

Término / Sigla	Significado y Descripción Técnica
QoS	Calidad de Servicio (<i>Quality of Service</i>) en protocolos de transporte ROS 2.
RNEA	Algoritmo Recursivo de Newton-Euler (<i>Recursive Newton-Euler Algorithm</i>).
RMSE	Raíz del Error Cuadrático Medio (<i>Root Mean Square Error</i>).
ROS / ROS 2	Sistema Operativo de Robots (<i>Robot Operating System</i> versión 2).
RT	Tiempo Real (<i>Real-Time</i>).
SNN	Red Neuronal de Impulsos (<i>Spiking Neural Network</i>).
UR3e	Robot manipulador colaborativo industrial de 6 GDL de Universal Robots.
URDF	Formato Unificado de Descripción de Robots (<i>Unified Robot Description Format</i>).
VoBo	Visto Bueno de aprobación emitido por el jurado o asesores.

Simbología

En la Tabla 2 se detallan las variables matemáticas, operadores, vectores y matrices empleados en la formulación cinemática, dinámica y de control, especificando sus unidades en el Sistema Internacional (SI).

Cuadro 2: Simbología matemática y magnitudes físicas del sistema mecatrónico.

Símbolo	Descripción Física o Matemática	Unidad (SI)
<i>Cinemática y Variables Articulares:</i>		
$\mathbf{q} = [q_1, \dots, q_6]^T$	Vector de posiciones articulares generalizadas	rad
$\dot{\mathbf{q}} = [\dot{q}_1, \dots, \dot{q}_6]^T$	Vector de velocidades articulares	rad/s
$\ddot{\mathbf{q}} = [\ddot{q}_1, \dots, \ddot{q}_6]^T$	Vector de aceleraciones articulares	rad/s ²
$\mathbf{q}_d, \dot{\mathbf{q}}_d, \ddot{\mathbf{q}}_d$	Trayectorias articular deseada (posición, velocidad y aceleración)	rad, rad/s, rad/s ²
$\mathbf{e} = \mathbf{q}_d - \mathbf{q}$	Vector de error de seguimiento de posición articular	rad
$\dot{\mathbf{e}} = \dot{\mathbf{q}}_d - \dot{\mathbf{q}}$	Vector de error de velocidad articular	rad/s
α_{i-1}	Parámetro DH modificado: ángulo de torsión de eslabón	rad
a_{i-1}	Parámetro DH modificado: longitud de eslabón	m
d_i	Parámetro DH modificado: desplazamiento en el eje articular	m
θ_i	Parámetro DH modificado: variable angular articular	rad
$\mathbf{R}_i^{i-1}$	Matriz de rotación del marco coordenado i respecto al marco $i - 1$	Adimensional
$\mathbf{P}_i^{i-1}$	Vector de traslación del origen $i - 1$ al origen i expresado en el marco i	m
$\mathbf{z}_0$	Vector unitario sobre el eje de rotación articular $[0, 0, 1]^T$	Adimensional
<i>Cinemática Diferencial y Dinámica RNEA (Paso hacia Adelante):</i>		
$\boldsymbol{\omega}_i$	Vector de velocidad angular del eslabón i expresado en su propio marco	rad/s
$\dot{\boldsymbol{\omega}}_i$	Vector de aceleración angular del eslabón i	rad/s ²
$\dot{\mathbf{v}}_i$	Vector de aceleración lineal del origen del marco coordenado i	m/s ²
$\dot{\mathbf{v}}_{c,i}$	Vector de aceleración lineal del centro de masa del eslabón i	m/s ²
$\mathbf{r}_{c,i}$	Vector de posición local del centro de masa del eslabón i	m
$\mathbf{g} = [0, 0, 9,81]^T$	Vector de aceleración de la gravedad terrestre	m/s ²

Continúa en la siguiente página...

Símbolo	Descripción Física o Matemática	Unidad (SI)
<i>Dinámica Analítica y Esfuerzos RNEA (Paso hacia Atrás):</i>		
m_i	Masa total del eslabón i	kg
I_i	Tensor de inercia baricéntrico del eslabón i expresado en su marco local	kg · m ²
F_i	Fuerza inercial total que actúa sobre el eslabón i	N
N_i	Momento inercial total que actúa sobre el eslabón i	N · m
f_i	Fuerza ejercida por el eslabón $i - 1$ sobre el eslabón i	N
n_i	Par/momento ejercido por el eslabón $i - 1$ sobre el eslabón i	N · m
$\tau = [\tau_1, \dots, \tau_6]^T$	Vector de pares motores netos generalizados aplicados a las articulaciones	N · m
τ_{rnea}	Par dinámico de prealimentación calculado por RNEA	N · m
τ_{cmd}	Par de comando total enviado a las interfaces de esfuerzo de los motores	N · m
$M(q)$	Matriz de masa e inercia del manipulador (6×6)	kg · m ²
$C(q, \dot{q})$	Matriz de términos centrífugos y de Coriolis (6×6)	N · m · s/rad
$g(q)$	Vector de pares gravitacionales articulares (6×1)	N · m
<i>Control Automático y Parámetros de Redes Neuronales:</i>		
K_p, K_d, K_i	Matrices de ganancias de retroalimentación proporcional, derivativa e integral	N · m/rad, N · m/s/rad, N · m/(rad · s)
a_{cmd}	Vector de aceleración de control auxiliar desacoplada	rad/s ²
$X \in \mathbb{R}^{42}$	Vector de entrada a la red neuronal (7 subgrupos de 6 articulaciones)	Dimensiones mixtas
$y \in \mathbb{R}^6$	Vector de salida predicho por la red (par estimado para 6 articulaciones)	N · m
μ_x, σ_x	Vectores de media y desviación estándar para normalización de entrada	Dimensiones mixtas
μ_y, σ_y	Vectores de media y desviación estándar para desnormalización de salida	N · m
S	Factor de escala de cuantización (<i>Scale factor</i>)	Adimensional
Z	Punto cero entero de compensación de cuantización (<i>Zero-point</i>)	Adimensional
q_{int8}	Valor entero cuantizado a 8 bits de un operando o peso	Adimensional
T_s	Periodo de muestreo del bucle de control de tiempo real (10 ms = 100 Hz)	s

Introducción

Los robots manipuladores son componentes esenciales en la automatización industrial, la cirugía asistida, la exploración espacial y una creciente variedad de aplicaciones de servicio, gracias a su capacidad para realizar tareas de manipulación con precisión y repetibilidad [6]. El control efectivo de estos sistemas es fundamental para su desempeño. Tradicionalmente, se han empleado técnicas de control clásico, como el control Proporcional-Integral-Derivativo (PID) o el control por par calculado, que han demostrado ser robustas para tareas definidas y con modelos dinámicos precisos del robot [6]. Sin embargo, la creciente demanda de mayor autonomía, adaptabilidad a entornos no estructurados y la capacidad para manejar interacciones complejas ha impulsado la adopción de enfoques basados en Inteligencia Artificial (IA), particularmente las Redes Neuronales Artificiales (ANNs) y las Redes Neuronales Profundas (DNNs) [7, 8].

A pesar de sus ventajas, la implementación de DNNs en sistemas robóticos conlleva desafíos significativos. Estos modelos suelen ser computacionalmente intensivos, caracterizados por un gran número de parámetros y una alta densidad de operaciones aritméticas, lo que se traduce en un considerable consumo energético y una fuerte demanda de recursos de memoria y procesamiento [9, 10]. Estas exigencias son particularmente problemáticas para las plataformas robóticas autónomas, que operan con fuentes de alimentación y recursos computacionales limitados [11, 12].

El interés de este estudio surge de la necesidad de reducir estos costes computacionales y energéticos. Las Redes Neuronales Cuantizadas (QNNs), que reducen la precisión numérica de los pesos y activaciones de una red, ofrecen una vía prometedora para comprimir modelos y acelerar la inferencia, con el potencial de disminuir drásticamente el consumo energético y el uso de memoria [10, 13].

Este trabajo busca aportar conocimiento práctico y cuantitativo sobre la viabilidad y los beneficios de utilizar QNNs para el control eficiente de robots manipuladores, ofreciendo una perspectiva con un enfoque en la eficiencia energética de diferentes métodos de control de sistemas robóticos.

Enfoque mecatrónico

En este apartado se describe cómo el proyecto evalúa un sistema completo que integra la mecánica del robot, la electrónica de medición y actuación, y el algoritmo de control implementado.

Definición del problema

El control de robots es esencial para su implementación en la automatización industrial o en robótica de consumo, a medida que los robots se emplean en tareas más avanzadas o con entornos cambiantes o dinámicos, los métodos de control se vuelven más complejos y con esto, su coste computacional y energético aumentan [7, 8].

0.0.1. Multiplicación de matrices, procesamiento de señales y problemas de computación en tareas robóticas

Las multiplicaciones de matrices tienen consecuencia directa en la robótica ya que las operaciones matriciales están implicadas en todos sus aspectos, particularmente la multiplicación vector-matriz y las operaciones de multiplicación-acumulación. Las ecuaciones de la cinemática directa e inversa, el modelo dinámico del robot dado por las ecuaciones de Euler-Lagrange o Newton-Euler, así como los diferentes métodos de control pudiendo ir desde un PID con compensaciones dinámicas, hasta los basados en aprendizaje automático y redes neuronales, todos dependen del uso y operación de matrices y vectores.[9, 6]

Este tipo de operaciones se realizan repetidamente a una alta frecuencia, lo que conlleva un costo computacional significativo. La ineficiencia en la realización de estas operaciones provoca un deterioro en el rendimiento en tiempo real, y un incremento en el consumo energético, que tiene su origen en la arquitectura de los equipos de computo actuales.

0.0.2. Cuello de botella de Von Neumann

La arquitectura Von Neumann, es un tipo específico de arquitectura computacional en la que tanto los datos como las instrucciones se almacenan en una memoria común como se muestra en la figura 1 donde se detalla el uso de memoria para los datos e instrucciones.




Figura 1: Arquitectura Von Neumann original [1]

Aunque este modelo ha sido fundamental para la computación digital durante muchos años, tiene limitaciones inherentes a su diseño que surgen del uso intensivo de datos, debido a la separación física entre el CPU y la memoria. Esto conlleva la necesidad de transferir datos e instrucciones a través de un bus de memoria compartido, lo que se conoce como el *cuello de botella de Von Neumann*. [1, 14]

Este cuello de botella provoca una latencia significativamente elevada, producto de la espera constante de la CPU por datos e instrucciones desde la memoria, y en un consumo energético considerable debido al intenso tráfico de datos -conocido como *memory wall*. En algoritmos con alta demanda de acceso a memoria y operaciones repetitivas sobre datos (ejemplo, multiplicación de matrices), como un control robótico,

procesamiento en tiempo real y aprendizaje automático, estas limitaciones impactan directamente en el rendimiento y la eficiencia energética del sistema.

0.0.3. Proyección a futuro de la problemática energética

Tanto la robótica como la inteligencia artificial se perfilan hacia su integración en sistemas autónomos capaces de percibir diferentes entornos, aprender de su propia experiencia y tomar decisiones en tiempo real. Debido a la complejidad de estas implementaciones, la demanda computacional ha incrementado trayendo consigo un consumo energético cada vez mayor[12, 15]. Esto presenta un problema para robots autónomos, drones, exoesqueletos de asistencia o sistemas colaborativos humano-robot donde la fuente de energía está suministrada por baterías. Este alto consumo proviene de los sistemas de control que hacen un uso intensivo de datos en arquitecturas de cómputo basadas principalmente en la arquitectura Von Neumann poniendo en juego la viabilidad de dichos sistemas autónomos.

Conforme los modelos de IA se vuelven más profundos y los sensores generan mayores volúmenes de datos, este “muro energético” se vuelve cada vez más pronunciado. Con esta proyección, se resalta la necesidad de la investigación y exploración de diferentes paradigmas computacionales que ofrezcan una mejora significativa a la eficiencia energética.

Justificación

Debido a las restricciones de cómputo actuales en chips tradicionales, surge la necesidad de mejorar su desempeño energético explorando alternativas de control enfocadas en la eficiencia computacional y energética. Este proyecto se centra en la evaluación de un método de control alternativo denominado redes neuronales cuantizadas o Quantized Neural Networks (QNNs) como una vía para lograr una mejora sustancial en la eficiencia energética de los sistemas de control de robots manipuladores. El objetivo principal es realizar una comparación directa del consumo energético de un sistema de control basado en QNNs con un control clásico bajo una plataforma de pruebas como lo puede ser una FPGA. Las redes neuronales cuantizadas reducen sus bits de entrada provocando una reducción en su requerimiento de computo y provoca una reducción también en la precisión de salida de dicha red como se ve en la figura 2[16, 17, 18].

El enfoque mecatrónico es esencial, ya que el proyecto evaluará un sistema completo que integra la mecánica del robot, la electrónica de medición y actuación, y el algoritmo de control (QNN o tradicional) implementado en una plataforma de *hardware* específica. La comparación energética se realizará considerando el sistema en su conjunto, ofreciendo una perspectiva realista del impacto de la optimización neuronal en el consumo global del robot durante tareas de control.




Figura 2: Reducción de bits de entrada y de precisión en la salida por la cuantización [2]

Objetivo

0.0.4. Objetivo general

Evaluar el desempeño energético, de precisión y de recursos utilizados en la implementación de un control de lazo cerrado con una planta robótica con control tradicional y con una red neuronal cuantizada.

0.0.5. Objetivos específicos TT1

- Investigar el estado del arte de las redes neuronales cuantizadas (QNNs) aplicadas al control de sistemas robóticos, las metodologías de cuantización (Post-Training Quantization - PTQ y Quantization-Aware Training - QAT), y las técnicas para la estimación y comparación del consumo energético en plataformas de cómputo embebidas y tradicionales.
- Definir la arquitectura de una red neuronal artificial (ANN) adecuada para el control de posición de un robot manipulador, incluyendo el preprocesamiento de las señales de entrada necesarias para la red.
- Diseñar el sistema de control de posición basado en la ANN seleccionada (sin cuantizar) y establecer las métricas de rendimiento de control que servirán como línea base.
- Establecer una metodología detallada para la cuantización del modelo de red neuronal diseñado, seleccionando al menos dos niveles de precisión distintos (ej.,

INT6 y INT8) y las herramientas de software para llevar a cabo el proceso.

- Diseñar el plan experimental para la comparación energética y de rendimiento, definiendo los escenarios de prueba, las variables a medir (ej., latencia de inferencia, uso de memoria, consumo energético estimado/medido, precisión del control) y la configuración del entorno de pruebas (simulado y/o físico).
- Caracterizar y poner en marcha la plataforma robótica y su interfaz de control, asegurando la capacidad de implementar y evaluar los diferentes esquemas de control.
- Escribir en el documento escrito dichos avances en la investigación.

0.0.6. Objetivos específicos TT2

- Implementar el lazo de control numérico tradicional (ej. PID) de posición del efector final, tanto en simulación numérica, como en físico, con la finalidad de tener un *benchmark* para comparar con la red neuronal cuantizada, tanto en desempeño, recurso energético, etc.
- Entrenar, implementar y validar el sistema de control de posición basado en la red neuronal no cuantizada (ANN de punto flotante) en la plataforma robótica, evaluando su rendimiento de control y su perfil de consumo energético como segundo punto de referencia.
- Implementar los sistemas de control de posición basados en las redes neuronales cuantizadas (QNNs) para los niveles de precisión seleccionados en TT1, integrándolos con la plataforma robótica.
- Realizar estudio comparativo de ambas soluciones y evaluar el desempeño energético, de control, de recursos computacionales, y de recursos de hardware implementados.
- Analizar e interpretar los resultados experimentales para cuantificar las ventajas y desventajas de cada enfoque de control, con un énfasis particular en la eficiencia energética lograda por las QNNs y su relación con la precisión del control.
- Documentar la metodología, los resultados obtenidos, las conclusiones del estudio comparativo y las recomendaciones para futuras implementaciones de QNNs en control robótico.

Antecedentes

El control de robots manipuladores es un campo bien establecido con una amplia historia de técnicas desarrolladas para lograr un movimiento preciso y fiable. Antes de la prominencia de los enfoques basados en inteligencia artificial, el control robótico se fundamentaba en gran medida en modelos matemáticos del robot y su entorno.

0.0.7. Técnicas de control clásico para robots manipuladores

Los controladores para robots manipuladores se pueden clasificar ampliamente según el espacio en el que se ejerce el control (espacio articular o espacio de la tarea) y el grado en que utilizan un modelo dinámico del robot.

Una de las estrategias más directas y comúnmente implementadas es el control PID (Proporcional-Integral-Derivativo) independiente para cada articulación. En este enfoque, cada articulación del robot es tratada como un sistema de un solo grado de libertad, y se diseña un controlador PID para regular su posición y velocidad basándose en el error entre el estado deseado y el medido (Lynch & Park, 2017, Capítulo 11.2)[6]. La simplicidad de diseño como se muestra en la figura 3 y sintonización (aunque esta última puede ser tediosa para sistemas multigrado de libertad altamente acoplados) ha hecho del control PID una opción popular, especialmente cuando no se dispone de un modelo dinámico preciso del robot. Para mejorar el rendimiento, a menudo se complementa con un control por prealimentación (*feedforward*), que utiliza el modelo cinemático y, a veces, un modelo dinámico simplificado para calcular los pares/fuerzas articulares nominales necesarios para seguir una trayectoria deseada, ayudando al lazo de realimentación PID a compensar solo las perturbaciones y errores de modelado (Lynch & Park, 2017, Capítulo 11.3)[6].




Figura 3: Diagrama simplificado de un control PID [3].

Cuando se dispone de un modelo dinámico mas completo del robot como en la ecuación 1.

$$M(\theta)\ddot{\theta} + c(\theta, \dot{\theta}) + g(\theta) = \tau \quad (1)$$

Se pueden implementar estrategias de control basadas en modelo más sofisticadas. Una técnica fundamental es el control por par calculado (*computed torque control*) o control por dinámica inversa (*inverse dynamics control*). Este enfoque busca linealizar y desacoplar la dinámica del robot mediante una ley de control que cancela los términos no lineales y de acoplamiento. La idea es calcular los pares de motor necesarios utilizando

el modelo dinámico inverso y luego aplicar un control lineal simple (como un PID) sobre el sistema linealizado resultante. Bajo la suposición de un modelo dinámico perfecto, el robot se comportaría como un sistema lineal desacoplado, lo que permitiría un control de alta precisión[6].

Otras técnicas de control avanzado incluyen el control adaptativo, que ajusta los parámetros del controlador en línea para compensar incertidumbres en el modelo dinámico del robot o variaciones en la carga útil[19], y el control robusto, diseñado para mantener la estabilidad y el rendimiento a pesar de las incertidumbres acotadas del modelo y las perturbaciones externas. El control en el espacio de la tarea (*task space control*) también es crucial, donde el control se ejerce directamente sobre la posición y orientación del efector final del robot, utilizando el jacobiano para relacionar las velocidades del efector final con las velocidades articulares.

0.0.8. Transición hacia el control basado en Inteligencia Artificial (IA)

Si bien las técnicas de control clásico mencionadas son efectivas en muchas situaciones, su rendimiento puede degradarse significativamente en presencia de dinámicas no modeladas complejas, fricción no lineal, incertidumbres paramétricas grandes o cuando se requiere que el robot opere en entornos altamente no estructurados o interactúe de forma compleja con el entorno. La obtención de modelos dinámicos precisos puede ser costosa y difícil, y la sintonización de controladores PID para sistemas multivariables fuertemente acoplados es a menudo un desafío. Estas limitaciones han motivado la exploración de enfoques basados en inteligencia artificial (IA), y en particular las redes neuronales artificiales (ANNs) de las cuales su estructura se puede apreciar en la figura 4.




Figura 4: Estructura de una red neuronal (ANN) [4].

Las redes neuronales profundas (DNNs) mostradas en la figura 5, han emergido como herramientas poderosas para el aprendizaje de tareas de control complejas, como la cinemática inversa, el seguimiento de trayectorias y el aprendizaje por refuerzo para la manipulación[8, 20]. Estas técnicas permiten a los robots aprender de la experiencia y adaptarse a variaciones, superando en muchos casos las limitaciones de los controladores tradicionales.




Figura 5: Comparación de una ANN y una DNN [5].

Sin embargo, el éxito y la creciente complejidad de los modelos de DNNs vienen acompañados de una demanda computacional y un consumo energético considerables[9, 12]. El gran número de parámetros y las intensivas operaciones de multiplicación y acumulación (MAC) inherentes a estas redes plantean un desafío significativo para su despliegue en plataformas robóticas, las cuales a menudo operan con recursos de hardware limitados (memoria, capacidad de procesamiento) y restricciones energéticas, especialmente en aplicaciones móviles o autónomas[11, 21]. Esta tensión entre la capacidad de los modelos de IA y las limitaciones de las plataformas de despliegue ha impulsado una vasta investigación en la optimización y compresión de redes neuronales.

0.0.9. Estado del arte

Gestionar de manera eficaz sistemas robóticos en contextos donde la energía es limitada sigue siendo un reto constante y cada vez más relevante. Aunque las arquitecturas de cómputo tradicionales, en su mayoría basadas en el esquema de Von Neumann, han facilitado importantes desarrollos, presentan limitaciones estructurales, especialmente en lo referente al acceso a la memoria y al consumo energético, cuando se utilizan en tareas de control avanzadas o en aplicaciones de inteligencia artificial. Investigaciones recientes han mostrado un interés creciente por mejorar la eficiencia de los modelos de inteligencia artificial, lo cual se refleja en iniciativas como la compresión de redes neuronales y el estudio de enfoques de cómputo alternativos a los tradicionales.

Dentro de este panorama, el cómputo neuromórfico se perfila como una opción innovadora, inspirada en la forma en que el cerebro humano procesa información de manera eficiente y paralela[22]. Este enfoque se basa en la implementación de las redes neuronales de impulsos (SNN), las cuales funcionan a través de eventos discretos (conocidos como *spikes*) y presentan una dinámica temporal inherente, lo que las hace especialmente adecuadas para aplicaciones de control en tiempo real[20, 23]. Esta implementación

de las SNN al control se ha explorado desde su aplicación al péndulo-carro [24], hasta el control de brazos robot 3D mediante aprendizaje por refuerzo (RL)[8, 20].

En estos trabajos se hace énfasis en el potencial de las QNN para aprender políticas de control con un eficiente consumo energético. Sin embargo la implementación de estas redes en *hardware*, específicamente en plataformas reconfigurables como las FPGA, sigue siendo un área de oportunidad para la investigación. El diseño en conjunto del *hardware/software* es esencial para la configuración de la arquitectura de las QNNs dentro de los recursos de una FPGA, buscando el equilibrio entre rendimiento y consumo[16].

A pesar de estos avances aun existe la necesidad de estudios comparativos que cuantifiquen la eficiencia energética de estos controles neuromórficos frente a los enfoques tradicionales. Este proyecto busca llenar este vacío proporcionando una evaluación directa en una plataforma común aplicado a un robot manipulador.

Organización del documento

En el Capítulo 1 se aborda el marco de referencia en el que se sustenta el proyecto. En el Capítulo 2 se plantea el diseño del sistema, desglosando los requerimientos, la arquitectura y las propuestas de solución. En el Capítulo 3 se detalla la implementación técnica e integración de los módulos mecatrónicos. En el Capítulo 4 se analizan los resultados obtenidos técnica y económicamente. Finalmente, se presentan las conclusiones correspondientes.

1. Marco de Referencia

1.1. Marco teórico

Este proyecto se fundamenta en la intersección de varias disciplinas clave: la robótica de manipulación, el control automático, la inteligencia artificial (específicamente las redes neuronales) y las técnicas de optimización de modelos para la eficiencia computacional y energética.

1.1.1. Modelado y Control de Robots Manipuladores

Los robots manipuladores son sistemas mecánicos articulados cuyo movimiento y comportamiento se describen mediante modelos matemáticos precisos.

Cinemática La cinemática estudia la geometría del movimiento. La **cinemática directa** relaciona las variables articulares $\mathbf{q} \in \mathbb{R}^n$ (donde n es el número de grados de libertad) con la configuración (posición y orientación) del efector final $\mathbf{x} \in SE(3)$ mediante una función $\mathbf{x} = f(\mathbf{q})$. La **cinemática inversa** busca la función $\mathbf{q} = f^{-1}(\mathbf{x})$, que es esencial para el control de posición y puede ser no lineal y tener múltiples soluciones [6].

Dinámica El modelo dinámico de un robot manipulador relaciona los pares/fuerzas articulares aplicados $\boldsymbol{\tau} \in \mathbb{R}^n$ con las posiciones $\mathbf{q}$, velocidades $\dot{\mathbf{q}}$ y aceleraciones $\ddot{\mathbf{q}}$ articulares. La ecuación general de la dinámica en espacio de estados para un manipulador rígido de n grados de libertad se expresa tradicionalmente mediante la formulación de Lagrange-Euler [25, 6]:

$$\boldsymbol{\tau} = \mathbf{M}(\mathbf{q})\ddot{\mathbf{q}} + \mathbf{C}(\mathbf{q}, \dot{\mathbf{q}})\dot{\mathbf{q}} + \mathbf{g}(\mathbf{q}) \quad (2)$$

donde:

- $\mathbf{M}(\mathbf{q}) \in \mathbb{R}^{n \times n}$ es la matriz de masa e inercia del manipulador, simétrica y estrictamente definida positiva ($\mathbf{M}(\mathbf{q}) = \mathbf{M}^T(\mathbf{q}) > 0$).
- $\mathbf{C}(\mathbf{q}, \dot{\mathbf{q}}) \in \mathbb{R}^{n \times n}$ es la matriz de efectos centrífugos y de Coriolis, la cual satisface la propiedad fundamental de que la matriz $\mathbf{M}(\mathbf{q}) - 2\mathbf{C}(\mathbf{q}, \dot{\mathbf{q}})$ es antisimétrica (*skew-symmetric*).
- $\mathbf{g}(\mathbf{q}) \in \mathbb{R}^n$ es el vector de fuerzas y pares generados por la atracción gravitatoria sobre los eslabones.

Si bien la formulación explícita de Lagrange-Euler permite el análisis analítico formal de estabilidad, el cálculo simbólico de $\mathbf{M}(\mathbf{q})$ y $\mathbf{C}(\mathbf{q}, \dot{\mathbf{q}})$ presenta una complejidad computacional de orden $\mathcal{O}(n^4)$ o $\mathcal{O}(n^3)$, lo cual resulta computacionalmente prohibitivo para bucles de control de alta frecuencia en robots de 6 GDL. Por esta razón, para el cálculo en tiempo real de la dinámica inversa se utiliza el **Algoritmo Recursivo de Newton-Euler (RNEA)**, desarrollado originalmente por Luh, Walker y Paul [6, 25]. El RNEA reduce la complejidad a un orden lineal óptimo $\mathcal{O}(n)$, propagando las cinemáticas desde la base hasta el efector final y los balances de fuerza en sentido inverso.

Bajo la convención de parámetros Denavit-Hartenberg modificados (Craig), el algoritmo se divide en dos fases iterativas:

1. Propagación Cinemática Hacia Adelante ($i = 1, \dots, n$):

Partiendo de las condiciones iniciales en la base inmóvil ($\boldsymbol{\omega}_0 = \mathbf{0}$, $\dot{\boldsymbol{\omega}}_0 = \mathbf{0}$), y considerando la aceleración gravitacional simulada en el marco inercial $\dot{\mathbf{v}}_0 = [0, 0, 9.81]^T$ m/s² para incorporar la gravedad intrínsecamente sin cálculos adicionales, se propagan las velocidades y aceleraciones hacia el extremo del robot:

$$\boldsymbol{\omega}_i = (\mathbf{R}_i^{i-1})^T \boldsymbol{\omega}_{i-1} + \dot{q}_i \mathbf{z}_0 \quad (3)$$

$$\dot{\boldsymbol{\omega}}_i = (\mathbf{R}_i^{i-1})^T \dot{\boldsymbol{\omega}}_{i-1} + ((\mathbf{R}_i^{i-1})^T \boldsymbol{\omega}_{i-1}) \times (\dot{q}_i \mathbf{z}_0) + \ddot{q}_i \mathbf{z}_0 \quad (4)$$

$$\dot{\mathbf{v}}_i = (\mathbf{R}_i^{i-1})^T \dot{\mathbf{v}}_{i-1} + \dot{\boldsymbol{\omega}}_i \times \mathbf{P}_i^{i-1} + \boldsymbol{\omega}_i \times (\boldsymbol{\omega}_i \times \mathbf{P}_i^{i-1}) \quad (5)$$

donde $\mathbf{R}_i^{i-1}$ es la matriz de orientación del marco i respecto a $i-1$, $\mathbf{P}_i^{i-1}$ es el vector de traslación del origen $i-1$ al i expresado en el marco i , y $\mathbf{z}_0 = [0, 0, 1]^T$ define el eje unitario de rotación articular.

2. Balance Dinámico Hacia Atrás ($i = n, \dots, 1$):

Calculada la cinemática de cada eslabón, se obtiene la aceleración lineal en su respectivo centro de masa $\mathbf{r}_{c,i}$:

$$\dot{\mathbf{v}}_{c,i} = \dot{\mathbf{v}}_i + \dot{\boldsymbol{\omega}}_i \times \mathbf{r}_{c,i} + \boldsymbol{\omega}_i \times (\boldsymbol{\omega}_i \times \mathbf{r}_{c,i}) \quad (6)$$

Aplicando las leyes de Newton y Euler, se determinan la fuerza inercial neta $\mathbf{F}_i$ y el momento inercial baricéntrico $\mathbf{N}_i$ sobre cada eslabón:

$$\mathbf{F}_i = m_i \dot{\mathbf{v}}_{c,i} \quad (7)$$

$$\mathbf{N}_i = \mathbf{I}_i \dot{\boldsymbol{\omega}}_i + \boldsymbol{\omega}_i \times (\mathbf{I}_i \boldsymbol{\omega}_i) \quad (8)$$

donde m_i y $\mathbf{I}_i$ representan la masa y el tensor de inercia baricéntrico del eslabón i . Finalmente, el balance de fuerzas $\mathbf{f}_i$ y momentos $\mathbf{n}_i$ transmitidos a través de la articulación se propaga recursivamente desde el último eslabón hasta la base:

$$\mathbf{f}_i = \mathbf{R}_{i+1}^i \mathbf{f}_{i+1} + \mathbf{F}_i \quad (9)$$

$$\mathbf{n}_i = \mathbf{N}_i + \mathbf{R}_{i+1}^i \mathbf{n}_{i+1} + \mathbf{r}_{c,i} \times \mathbf{F}_i + \mathbf{P}_{i+1}^i \times (\mathbf{R}_{i+1}^i \mathbf{f}_{i+1}) \quad (10)$$

asumiendo que sobre el efector final no actúan fuerzas externas no compensadas ($\mathbf{f}_{n+1} = \mathbf{0}$, $\mathbf{n}_{n+1} = \mathbf{0}$). El par dinámico que debe suministrar el actuador de la articulación i corresponde a la proyección del momento $\mathbf{n}_i$ sobre el eje de rotación:

$$\tau_{rnea,i} = \mathbf{n}_i^T \mathbf{z}_0 \quad (11)$$

Esta formulación analítica recursiva es la que se ejecuta determinísticamente en el nodo de control en C++ a una frecuencia de 100 Hz, proporcionando tanto el par de desacoplamiento para el control clásico como los vectores de referencia de pares $\boldsymbol{\tau}_{rnea}$ que enriquecen el espacio de características de entrada de la red neuronal.

Estrategias de Control Clásicas

- **Control PID Independiente por Articulación:** Para cada articulación i , la ley de control es:

$$\tau_i(t) = K_{p_i} e_i(t) + K_{i_i} \int_0^t e_i(\lambda) d\lambda + K_{d_i} \frac{de_i(t)}{dt} \quad (12)$$

donde $e_i(t) = q_{d_i}(t) - q_i(t)$ es el error de la articulación i , y K_p, K_i, K_d son las ganancias proporcional, integral y derivativa respectivamente. A menudo se complementa con un término de prealimentación (*feedforward*) τ_{ff_i} para mejorar el seguimiento de trayectorias[6]:

$$\tau_i = \tau_{ff_i} + K_{p_i} e_i + K_{i_i} \int e_i dt + K_{d_i} \dot{e}_i \quad (13)$$

- **Control por Par Calculado (*Computed Torque Control*):** Esta técnica utiliza el modelo dinámico para cancelar las no linealidades. Si se tiene un modelo estimado $\hat{M}(\mathbf{q})$, $\hat{\mathbf{c}}(\mathbf{q}, \dot{\mathbf{q}})$, y $\hat{\mathbf{g}}(\mathbf{q})$, la ley de control es:

$$\boldsymbol{\tau} = \hat{M}(\mathbf{q}) \mathbf{a}_{cmd} + \hat{\mathbf{c}}(\mathbf{q}, \dot{\mathbf{q}}) + \hat{\mathbf{g}}(\mathbf{q}) \quad (14)$$

donde $\mathbf{a}_{cmd}$ es una aceleración de comando, comúnmente diseñada usando un control lineal sobre el error:

$$\mathbf{a}_{cmd} = \ddot{\mathbf{q}}_d + K_d(\dot{\mathbf{q}}_d - \dot{\mathbf{q}}) + K_p(\mathbf{q}_d - \mathbf{q}) \quad (15)$$

Bajo la suposición de un modelo perfecto ($\hat{M} = M$, $\hat{\mathbf{c}} = \mathbf{c}$, $\hat{\mathbf{g}} = \mathbf{g}$), el sistema en lazo cerrado se comportaría como un conjunto de n integradores dobles desacoplados: $\ddot{\mathbf{e}} + K_d \dot{\mathbf{e}} + K_p \mathbf{e} = \mathbf{0}$, permitiendo un control preciso [6].

1.1.2. Redes Neuronales Artificiales para el Control Robótico

Las Redes Neuronales Artificiales (ANN), y sus variantes profundas (DNN), pueden aprender mapeos complejos a partir de datos, lo que las hace adecuadas para tareas de control robótico donde los modelos analíticos son imprecisos o difíciles de obtener.

Pueden usarse para aprender la cinemática inversa $\mathbf{q} = f_{NN}(\mathbf{x}; \boldsymbol{\theta}_{NN})$, la dinámica inversa $\boldsymbol{\tau} = f_{NN}(\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}}; \boldsymbol{\theta}_{NN})$, o directamente políticas de control $\boldsymbol{\tau} = \pi_{NN}(\text{estado}; \boldsymbol{\theta}_{NN})$ mediante aprendizaje por refuerzo [8, 20], donde $\boldsymbol{\theta}_{NN}$ representa los parámetros de la red.

Las operaciones fundamentales en las DNN, como las convoluciones o las capas totalmente conectadas, se basan en un gran número de operaciones de Multiplicación y Acumulación (MAC): $y = \sum_i w_i x_i + b$ para una neurona, o de forma matricial $\mathbf{Y} = \mathbf{W}\mathbf{X} + \mathbf{B}$ para una capa, lo que resulta en una alta carga computacional y accesos a memoria [9].

1.1.3. Estrategias de Optimización de Redes Neuronales

La alta demanda computacional y energética de las DNN, detallada en secciones previas, se convierte en el principal problema a tratar en este proyecto. El objetivo general es reducir la complejidad del modelo (en términos de parámetros y operaciones), el tamaño en memoria, la latencia de inferencia y el consumo energético, manteniendo al mismo tiempo la precisión de la tarea lo más alta posible. Las principales estrategias incluyen la poda de redes, el desarrollo de arquitecturas eficientes, el uso de paradigmas alternativos como las redes neuronales de impulsos, y la cuantización de redes neuronales, siendo esta última el foco central de este proyecto.

Poda de Redes (*Neural Pruning*) La poda de redes neuronales se basa en la observación de que muchos modelos de DNNs están sobreparametrizados, conteniendo un gran número de pesos o neuronas que contribuyen poco o nada al rendimiento final [10]. El objetivo de la poda es identificar y eliminar estos elementos redundantes.

Tipos de Poda:

- **Poda No Estructurada (*Unstructured Pruning*):** Consiste en eliminar pesos individuales de la red. Se establece un criterio de importancia (saliencia) para cada peso w_{ij} , y aquellos por debajo de un umbral son eliminados (su valor se fija a cero). Formalmente, si $\mathcal{T}$ es el umbral:

$$w'_{ij} = \begin{cases} w_{ij} & \text{si } \text{saliencia}(w_{ij}) > \mathcal{T} \\ 0 & \text{en caso contrario} \end{cases} \quad (16)$$

- **Poda Estructurada (*Structured Pruning*):** En lugar de eliminar pesos individuales, se eliminan grupos de pesos o estructuras enteras, como neuronas completas, filtros convolucionales completos o incluso capas. Por ejemplo, se puede calcular la importancia de un filtro convolucional (ej., sumando las magnitudes

de sus pesos o usando su norma L1/L2) y eliminar los filtros menos importantes. Esto resulta en redes más pequeñas y con una estructura regular, lo que facilita la aceleración en hardware estándar, ya que las dimensiones de las matrices y tensores se reducen directamente [10].

Proceso de Poda: La poda puede realizarse de forma iterativa: se entrena la red, se podan los elementos menos importantes, y luego se re-entrena (*fine-tuning*) la red podada para recuperar la precisión que se haya podido perder. Este ciclo de podar y re-entrenar puede repetirse varias veces. Alternativamente, existen métodos de poda *one-shot* que intentan realizar la poda en una sola etapa, a veces durante el mismo entrenamiento o inmediatamente después, como la propuesta de “*Single-shot pruning and quantization*” de Jiang [17].

Redes Neuronales de Impulsos (*Spiking Neural Networks* - SNN) Las SNN representan un paradigma de computación neuronal alternativo, inspirado más directamente en el funcionamiento de las neuronas biológicas. Se las considera la “tercera generación” de redes neuronales y se caracterizan por procesar información mediante secuencias de eventos discretos en el tiempo, denominados impulsos (*spikes*).

Modelos Neuronales de SNN: A diferencia de las neuronas de las ANN que calculan una salida analógica (o un valor de activación continuo), las neuronas en las SNN integran las señales de entrada (*spikes* ponderados de otras neuronas) a lo largo del tiempo, y generan un *spike* de salida solo cuando su potencial de membrana alcanza un umbral específico.

- ***Leaky Integrate-and-Fire* (LIF):** Es uno de los modelos más simples y computacionalmente eficientes. El potencial de membrana $v(t)$ de una neurona LIF evoluciona según la ecuación diferencial:

$$\tau_m \frac{dv(t)}{dt} = -(v(t) - v_{rest}) + R_{in}I(t) \quad (17)$$

donde τ_m es la constante de tiempo de la membrana, v_{rest} es el potencial de reposo, R_{in} es la resistencia de entrada, e $I(t)$ es la corriente sináptica total de entrada. Cuando $v(t)$ alcanza el umbral v_{th} , la neurona emite un *spike* y $v(t)$ se reinicia (ej., a $v_{reset} < v_{th}$) y puede entrar en un periodo refractario.

- **Modelo de Izhikevich:** Es un modelo bidimensional que puede reproducir una rica variedad de patrones de disparo observados en neuronas biológicas (ej., *regular spiking*, *bursting*, *chattering*, *fast spiking*, etc.) con solo cuatro parámetros ajustables (a, b, c, d) y un par de ecuaciones diferenciales acopladas:

$$\frac{dv}{dt} = 0,04v^2 + 5v + 140 - u + I \quad (18)$$

$$\frac{du}{dt} = a(bv - u) \quad (19)$$

Con la condición de reseteo post-impulso: si $v(t) \geq v_{peak}$ (usualmente 30 mV), entonces $v(t) \leftarrow c$ y $u(t) \leftarrow u(t) + d$. La variable u representa una variable de recuperación de la membrana. Este modelo es utilizado, por ejemplo, en la tesis del Dr. Juárez Lora para la implementación de una plataforma neuromórfica [7].

Las SNN ofrecen un gran potencial para la eficiencia energética, especialmente cuando se implementan en *hardware* neuromórfico dedicado (ej., Loihi de Intel, TrueNorth de IBM, SpiNNaker) que está diseñado para manejar la comunicación basada en eventos y la computación dispersa en el tiempo y el espacio [26].

Redes Neuronales Cuantizadas (*Quantized Neural Networks* - QNN) La cuantización es una técnica de compresión y optimización que reduce la precisión numérica utilizada para representar los pesos $\mathbf{w}$ y/o las activaciones $\mathbf{a}$ de una red neuronal. Esta es la estrategia de optimización central de este proyecto.

Principios Fundamentales y Proceso de Cuantización: El objetivo es transformar los parámetros y activaciones, típicamente almacenados como números de punto flotante de 32 bits (FP32), a representaciones de enteros de baja precisión (ej., INT6, INT4) o formatos de punto fijo. Una cuantización **uniforme afín** (asimétrica) de un valor real x a un entero cuantizado x_q de k bits se define mediante una escala $S \in \mathbb{R}^+$ y un punto cero $Z \in \mathbb{Z}$ (que es un entero de k bits y representa el mapeo del valor real 0,0):

$$x_q = \text{clamp} \left(\text{round} \left(\frac{x}{S} \right) + Z, N_{min}^{(k)}, N_{max}^{(k)} \right) \quad (20)$$

donde $\text{round}(\cdot)$ es el redondeo al entero más cercano, y $\text{clamp}(\cdot, N_{min}^{(k)}, N_{max}^{(k)})$ asegura que x_q permanezca dentro del rango representable por k bits (ej., $[0, 2^k - 1]$ para k bits sin signo, o $[-2^{k-1}, 2^{k-1} - 1]$ para k bits con signo). La escala S determina el tamaño del paso de cuantización, y Z permite que el rango de cuantización no sea necesariamente simétrico alrededor del cero real. La operación inversa (de-cuantización) para obtener una aproximación de x es:

$$\hat{x} = S(x_q - Z) \quad (21)$$

En la cuantización **uniforme simétrica**, el punto cero Z se asume como 0 (o el punto cero de la representación entera es el cero real), y el mapeo es simétrico alrededor del origen. La escala S se determina a partir del valor absoluto máximo del rango. La determinación de los parámetros S y Z es crucial:

- **Min-Max Quantization:** $S = \frac{\max(x_{tensor}) - \min(x_{tensor})}{N_{max}^{(k)} - N_{min}^{(k)}}$ y Z se deriva para alinear el cero.
- Otros métodos buscan minimizar el error de cuantización, por ejemplo, minimizando la divergencia KL entre la distribución de los valores FP32 y los valores cuantizados, o utilizando percentiles para ser robustos a outliers.

La cuantización puede aplicarse con diferente granularidad:

- **Por Tensor:** Un único par (S, Z) para todo un tensor (ej., todos los pesos de una capa).
- **Por Canal:** Un par (S, Z) diferente para cada canal de salida de un filtro convolucional o para cada fila/columna de una matriz de pesos. Generalmente ofrece mejor precisión que la cuantización por tensor, especialmente para capas con distribuciones de pesos muy variables entre canales.

Tipos de Datos de Baja Precisión y Formatos de Punto Fijo: Mientras que INT6 es un objetivo común y bien soportado, la investigación explora precisiones aún menores como INT4, INT2 (ternario: $\{-1, 0, 1\}$) o INT1 (binario: $\{-1, 1\}$ o $\{0, 1\}$) [27]. La representación de **punto fijo** $Q(I, F)$ denota un número con I bits para la parte entera y F bits para la parte fraccionaria (más un bit de signo si es necesario). El valor real es $X_{int} \cdot 2^{-F}$, donde X_{int} es la representación entera. La cuantización moderna a menudo prefiere el formalismo de escala y punto cero para enteros, ya que es más flexible y se adapta mejor a las capacidades del *hardware*.

Post-Training Quantization (PTQ): PTQ se aplica a un modelo ya entrenado en FP32. El proceso típicamente implica:

1. **Calibración:** Se pasa un pequeño conjunto de datos representativos (usualmente sin etiquetas, del conjunto de entrenamiento o validación) a través del modelo FP32 para recolectar estadísticas de los rangos de activación de cada capa. Los rangos de los pesos se obtienen directamente del modelo entrenado.
2. **Cálculo de Parámetros de Cuantización:** Usando los rangos observados, se calculan S y Z para cada tensor a cuantizar.
3. **Conversión del Modelo:** Los pesos se cuantizan y almacenan en el formato de baja precisión. Las activaciones se cuantizarán dinámicamente durante la inferencia, o se insertarán operaciones de cuantización/de-cuantización en el grafo.

Para mejorar la precisión de PTQ, especialmente con pocos bits, se utilizan técnicas como:

- **Bias Correction:** Se ajustan los vectores de sesgo de las capas para compensar el error medio introducido por la cuantización de los pesos, que puede desplazar la media de las activaciones.
- **Cross-Layer Equalization (CLE):** Se re-escalan los pesos entre capas consecutivas para igualar sus rangos dinámicos antes de la cuantización, lo que puede reducir el error de cuantización global. Métodos como AdaRound ajustan los pesos de forma más sofisticada para minimizar el error de redondeo [10, 28].

Quantization-Aware Training (QAT): QAT simula el proceso de cuantización durante la fase de entrenamiento (o más comúnmente, durante una fase de re-entrenamiento o *fine-tuning* a partir de un modelo FP32 pre-entrenado). Esto se logra insertando nodos de **Fake Quantization (FQ)** en el grafo computacional, típicamente después de los pesos y de las activaciones.

- **Forward Pass:** En un nodo FQ, la entrada x (FP32) se cuantiza a k bits (simulando el efecto de S y Z) y luego se de-cuantiza inmediatamente para obtener $\hat{x}$ (FP32 con valores discretos). Este $\hat{x}$ se pasa a la siguiente operación.

$$\hat{x}_{FQ} = S \left(\text{clamp} \left(\text{round} \left(\frac{x}{S} \right) + Z, N_{min}^{(k)}, N_{max}^{(k)} \right) - Z \right) \quad (22)$$

- **Backward Pass:** El gradiente de la función de pérdida con respecto a $\hat{x}_{FQ}$ debe propagarse hacia x . Dado que la función $\text{round}(\cdot)$ tiene gradiente cero casi en todas partes, se utiliza el **Straight-Through Estimator (STE)**, que simplemente copia el gradiente: $\frac{\partial L}{\partial x} = \frac{\partial L}{\partial \hat{x}_{FQ}}$. Es decir, se asume $\frac{\partial \hat{x}_{FQ}}{\partial x} \approx 1$.

QAT permite que los pesos del modelo se ajusten durante el entrenamiento para compensar la pérdida de precisión introducida por la cuantización, resultando generalmente en una mayor exactitud final en comparación con PTQ, especialmente para cuantización a muy bajos bits [10, 28].

Cuantización de Precisión Mixta (*Mixed-Precision Quantization*): No todas las capas de una red neuronal tienen la misma sensibilidad a la cuantización. Algunas pueden tolerar precisiones muy bajas (ej., INT4) con poca degradación, mientras que otras (ej., la primera o la última capa) pueden requerir mayor precisión (ej., INT6 o incluso FP16) para mantener el rendimiento general del modelo. La cuantización de precisión mixta asigna diferentes números de bits a diferentes capas o tensores, buscando un óptimo global entre compresión/eficiencia y precisión. La determinación de la política de asignación de bits es un problema complejo. Los enfoques incluyen:

- Métodos basados en análisis de sensibilidad heurístico.
- Técnicas de búsqueda automatizada como AutoML o aprendizaje por refuerzo, donde un agente aprende a asignar precisiones.
- Optimización multiobjetivo, como en MOHAQ de Rezk (2022)[28], que utiliza algoritmos genéticos para encontrar soluciones en el frente de Pareto de error vs. recursos de hardware.

Impacto en Operaciones Aritméticas y Eficiencia: La cuantización transforma las operaciones de punto flotante en operaciones enteras. Consideremos la multiplicación de matrices o convoluciones, que son sumas de productos: $y = \sum w_i x_i + b$. Si w_i y x_i son cuantizados a k_w y k_x bits respectivamente, con parámetros (S_w, Z_w) y (S_x, Z_x) :

$$S_y(y_q - Z_y) \approx \sum_i [S_w(w_{q_i} - Z_w)][S_x(x_{q_i} - Z_x)] + S_b(b_q - Z_b) \quad (23)$$

Desarrollando y agrupando las escalas:

$$y_q \approx Z_y + \frac{S_w S_x}{S_y} \sum_i (w_{q_i} - Z_w)(x_{q_i} - Z_x) + \frac{S_b}{S_y} (b_q - Z_b) \quad (24)$$

La suma $\sum_i (w_{q_i} - Z_w)(x_{q_i} - Z_x)$ involucra productos y acumulaciones de enteros, que se realizan típicamente en una precisión mayor (ej., INT32). El factor de re-escala $M = \frac{S_w S_x}{S_y}$ (y similar para el sesgo) se calcula offline y puede aproximarse por un producto de un entero y una potencia de dos para ser implementado con multiplicaciones enteras y bit-shifts, evitando operaciones de punto flotante en tiempo de inferencia. Las operaciones de normalización de batch (Batch Normalization), si presentes, a menudo se “pliegan” en los pesos y sesgos de las capas lineales o convolucionales precedentes antes de la cuantización, eliminando la necesidad de calcularlas durante la inferencia cuantizada. Los beneficios son una reducción significativa en el tamaño del modelo (ej., INT6 vs FP32 es una reducción de aproximadamente 4 veces), menor ancho de banda de memoria, y aceleración de cómputo debido a que las operaciones enteras son inherentemente más rápidas y menos costosas energéticamente que las de punto flotante en la mayoría de los procesadores y hardware dedicado.

1.2. Marco procedimental

1.2.1. Metodología mecatrónica

Para la gestión y desarrollo de este proyecto de investigación, que inherentemente combina elementos de diseño de software (controladores neuronales, cuantización), integración de hardware (plataforma robótica, sistema de cómputo) y experimentación (simulación y/o pruebas físicas), se ha optado por adoptar y adaptar el marco de trabajo ágil **Scrum**. Esta elección se fundamenta en la flexibilidad de *Scrum* para manejar la incertidumbre inherente a la investigación, su énfasis en la entrega incremental de valor y la colaboración continua, son aspectos importantes para un proyecto de con un componente significativo de desarrollo tecnológico y evaluación comparativa [29].

Scrum, originalmente se crea para el desarrollo de software, pese a eso se ha aplicado al desarrollo de proyectos de ingeniería [30]. Su naturaleza iterativa e incremental permite la validación y verificación constante del progreso, un principio fundamental en el diseño mecatrónico.

Eventos de *Scrum* Adaptados al Proyecto Los eventos de *Scrum* proporcionarán la estructura para la inspección y adaptación regular:

- **Sprint:** Serán iteraciones de duración fija (ej., 2 a 4 semanas) durante las cuales se trabajará para completar un conjunto de objetivos del *Product Backlog* y crear un Incremento utilizable o evaluable del proyecto. La duración se definirá al inicio de cada fase (TT1 y TT2).
- **Planificación del *Sprint* (*Sprint Planning*):** Al inicio de cada *Sprint*, se seleccionarán los ítems de mayor prioridad del *Product Backlog* que se pueden

completar en el *Sprint* y definirá un Objetivo del *Sprint* (*Sprint goal*). Se desglosarán las tareas necesarias (*Sprint Backlog*).

- **Reuniones de Avance (Adaptación del *Daily Scrum*):** Se realizarán reuniones periódicas (ej., semanales) con los asesores para inspeccionar el progreso hacia el Objetivo del *Sprint*, discutir los trabajos completados, los que están en curso, los problemas encontrados y planificar los siguientes pasos. Esto reemplaza al *Daily Scrum* en un contexto de trabajo individual supervisado.
- **Revisión del *Sprint* (*Sprint Review*):** Al final de cada *Sprint*, se presentará el Incremento logrado (ej., un módulo de software funcional, resultados de simulación, un avance en la investigación documentado) a los asesores. Se discutirá el trabajo completado y se recogerá retroalimentación que podrá influir en el *Product Backlog* y en la planificación de *Sprints* futuros.
- **Retrospectiva del *Sprint* (*Sprint Retrospective*):** Después de la Revisión del *Sprint*, se realizará una reflexión sobre el proceso seguido durante el *Sprint*: qué funcionó bien, qué se podría mejorar y qué acciones concretas se tomarán para optimizar la eficiencia y efectividad en el siguiente *Sprint*.

Artefactos de *Scrum* Adaptados al Proyecto Los artefactos de *Scrum* proporcionarán transparencia y oportunidades para la inspección y adaptación:

- ***Product Backlog*:** Será una lista ordenada y dinámica de todo lo que se necesita para el proyecto. Incluirá los objetivos específicos de TT1 y TT2, desglosados en tareas de investigación, diseño, desarrollo, experimentación y documentación.
- ***Sprint Backlog*:** Es el conjunto de ítems del *Product Backlog* seleccionados para un *Sprint*, más un plan para entregar el Incremento y alcanzar el Objetivo del *Sprint*.
- **Incremento:** Es la suma de todos los ítems del *Product Backlog* completados durante un *Sprint* y todos los *Sprints* anteriores. Al final de cada *Sprint*, el nuevo Incremento debe ser *utilizable* o **evaluable** en el contexto del proyecto, lo que significa que representa un avance tangible y verificable hacia los objetivos generales.

Esta adopción de la metodología *Scrum* proporciona una planificación estructurada pero flexible, fomentando el progreso constante, la adaptación de los hallazgos y la entrega de resultados de forma incremental.

2. Diseño del sistema

2.1. Diseño conceptual

El diseño conceptual representa la fase inicial del desarrollo mecatrónico en la cual se traducen las necesidades del problema en especificaciones técnicas formales y se definen las alternativas de solución bajo el marco metodológico ágil adoptado (*Scrum*).

A diferencia de los modelos lineales tradicionales que demandan una definición estática y exhaustiva antes de cualquier desarrollo, en este proyecto la arquitectura se concibe para evolucionar de manera incremental a través de *Sprints*, manteniendo una clara separación de responsabilidades y facilitando la validación temprana mediante simulación fidedigna de alta fidelidad, con miras a una transferencia directa y desriesgada hacia la plataforma física en la fase subsecuente.

2.1.1. Necesidades - requerimientos

Con el propósito de garantizar un control articular preciso, estable y computacionalmente eficiente sobre el manipulador robótico de 6 grados de libertad (GDL), se establecieron los requerimientos de ingeniería que rigen el diseño del sistema. Estos se dividen en requerimientos funcionales (RF), que describen las operaciones y capacidades dinámicas que el sistema debe ejecutar, y requerimientos no funcionales (RNF), que imponen restricciones de tiempo real, seguridad, determinismo y compatibilidad con estándares industriales de robótica y aprendizaje profundo. La Tabla 3 sintetiza estos requerimientos con sus correspondientes métricas y criterios de aceptación.

2.1.2. Arquitectura funcional (funciones)

En congruencia con el marco ágil de desarrollo (*Scrum*) y alejándose deliberadamente de los esquemas mecanicistas estáticos de la ingeniería tradicional (como la descomposición rígida en flujos de materia, energía e información de la norma VDI 2206), la arquitectura funcional de este sistema se concibe como un **pipeline desacoplado de procesamiento de datos y servicios en tiempo real**. Esta estructura permite que cada servicio opere como un incremento de software modular, verificable de forma independiente y coordinado a través de interfaces estandarizadas.

La descomposición funcional del sistema se estructura en los siguientes cinco servicios esenciales:

1. **Servicio de Planificación y Generación de Trayectorias:** Encargado de sintetizar las trayectorias articulares de referencia deseadas ($\mathbf{q}_d(t)$, $\dot{\mathbf{q}}_d(t)$, $\ddot{\mathbf{q}}_d(t)$). Emplea formulaciones polinomiales de quinto grado para garantizar que tanto la velocidad como la aceleración articular sean continuas (C^2), eliminando saltos bruscos en las fuerzas inerciales y preservando la vida mecánica de las transmisiones.
2. **Servicio de Supervisión y Bucle Crítico en Tiempo Real:** Núcleo central del controlador. En cada periodo de muestreo ($T_s = 2$ ms), este servicio adquiere el estado cinemático real del manipulador ($\mathbf{q}, \dot{\mathbf{q}}$) a través de las interfaces de hardware (`hardware_interface::HW_IF_POSITION` y `HW_IF_VELOCITY`), calcula el vector de error articular $\mathbf{e} = \mathbf{q}_d - \mathbf{q}$ y su derivada $\dot{\mathbf{e}}$, y evalúa analíticamente las ecuaciones recursivas de Newton-Euler (RNEA) para obtener el vector de pares nominales $\boldsymbol{\tau}_{RNEA}(\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}}_d)$.
3. **Servicio de Inferencia Inteligente Cuantizada:** Construye un vector de características normalizado de 42 dimensiones que condensa el estado cinemático

Cuadro 3: Requerimientos funcionales y no funcionales del sistema de control mecatrónico.

ID	Requerimiento	Descripción Técnica	Criterio / Métrica
Requerimientos Funcionales (RF)			
RF-01	Cinemática de 6 GDL	Control articular coordinado de las 6 articulaciones rotacionales del robot en espacio articular ($\mathbf{q} \in \mathbb{R}^6$).	Grados de libertad: 6. Error de seguimiento $e_q < 0,05$ rad.
RF-02	Bucle de control en tiempo real	Ejecución periódica determinista del lazo cerrado de control a una tasa mínima de 100 Hz, con escalabilidad a 500 Hz.	Periodo $T_s \leq 10$ ms (diseño nominal $T_s = 2$ ms).
RF-03	Compensación dinámica híbrida	Integración de un modelo dinámico analítico inverso (RNEA) acoplado a un módulo de compensación neuronal para dinámicas no modeladas.	Cálculo en línea de $\tau_{RNEA} + \tau_{NN}$.
RF-04	Cuantización a INT8	Compresión de pesos y activaciones a precisión entera de 8 bits (INT8) mediante cuantización post-entrenamiento (PTQ).	Reducción de tamaño $\geq 50\%$ (alcanzado: 74.4%).
RF-05	Saturación de seguridad	Acotamiento físico riguroso del vector de pares de comando τ_{cmd} para proteger la integridad estructural de los actuadores.	$ \tau_i \leq 55,0$ N·m, $\forall i \in \{1, \dots, 6\}$.
RF-06	Trayectorias suaves (C^2)	Generación de perfiles de referencia articular con continuidad de posición, velocidad y aceleración continuas mediante polinomios de 5to orden.	Continuidad matemática C^2 , libre de discontinuidades de par.
Requerimientos No Funcionales (RNF)			
RNF-01	Paridad Sim-to-Real	Compatibilidad nativa con ROS 2 Jazzy y el marco estándar <code>ros2_control</code> , permitiendo intercambiar el gemelo digital por el robot físico sin alterar el código de control.	Soporte para el driver <code>UniversalRobots_ROS2_Driver</code> y <code>gz_ros2_control</code> .
RNF-02	Determinismo temporal C++	Exclusión total de asignaciones dinámicas de memoria (<code>malloc</code> , <code>new</code>) en el método cíclico <code>update()</code> y uso de buffers no bloqueantes.	Jitter $< 100 \mu s$, uso de <code>RealtimeBuffer</code> .
RNF-03	Interoperabilidad de ML	Adopción del estándar abierto ONNX (<i>Open Neural Network Exchange</i>) y motor de inferencia C++ monohilo para erradicar latencias variables.	ONNX IR v9 / Opset 9, ejecución monohilo con ONNX Runtime.
RNF-04	Modularidad para plataforma neutra	Aislamiento funcional de los algoritmos para posibilitar su migración y benchmarking en hardware neutro (Microcontrolador vs. FPGA) en TT2.	Arquitectura desacoplada en librerías independientes y plugins.

actual, el estado deseado y la predicción física analítica. Mediante el motor de inferencia optimizado de ONNX Runtime ejecutado en modo monohilo dentro del espacio de memoria de C++, este servicio calcula la compensación de dinámica no modelada y fricción articular en precisión entera INT8, restituye la escala física de las magnitudes y aplica un esquema de saturación de seguridad acotado a $\pm 55,0 \text{ N} \cdot \text{m}$.

4. **Capa de Abstracción de Hardware (*Hardware Abstraction Layer*):** Gestionada a través de la interfaz estándar `ros2_control`, esta capa envía los pares de esfuerzo comandados (`HW_IF_EFFORT`) hacia los actuadores articulares. Su diseño modular permite que la misma consigna de control sea consumida de manera idéntica por el simulador de física avanzada (Gazebo Harmonic en TT1) o por el manipulador físico real (UR3e en TT2), aislando completamente el algoritmo de control de los detalles de bajo nivel del hardware.
5. **Servicio Asíncrono de Telemetría y Monitoreo:** Opera fuera del hilo crítico de control mediante el mecanismo no bloqueante `realtime_tools::RealtimeBuffer`, publicando los vectores de estado y pares a 100 Hz hacia el sistema de registro en formato MCAP (`ros2 bag`) para su análisis posterior y cálculo de errores RMS, sin inducir retardos ni variaciones de latencia (*jitter*) en el ciclo principal.

En la Figura 6 se ilustra el diagrama funcional del pipeline de datos y bucles de control mecatrónico.




Figura 6: Diagrama de la arquitectura funcional y flujo de datos en tiempo real del sistema de control inteligente bajo la metodología ágil.

2.1.3. Arquitectura física (módulos)

Para habilitar un desarrollo ágil por *Sprints* y facilitar la integración mecatrónica incremental, el sistema se divide físicamente en cuatro módulos cohesivos y desacoplados (M_1 a M_4). Esta división garantiza que las validaciones algorítmicas realizadas en TT1 constituyan la base directa para la transferencia física e integración en la plataforma neutra durante TT2:

- **Módulo 1 (M_1) – Planta Robótica y Entorno Sim-to-Real:** Comprende el manipulador robótico de 6 GDL Universal Robots UR3e (alcance de 500 mm, carga útil nominal de 3 kg) y su contraparte virtual de alta fidelidad. En TT1, la planta se modela rigurosamente en el simulador Gazebo Harmonic acoplado con el plugin `gz_ros2_control`, utilizando los descriptores cinemáticos y dinámicos oficiales (URDF/Xacro). Este entorno reproduce las inercias, masas y límites articulares reales del UR3e, garantizando que el controlador interactúe con interfaces de hardware idénticas a las del manipulador físico disponible para TT2.
- **Módulo 2 (M_2) – Control Dinámico Analítico y Lógica de Tiempo Real:** Contiene la formulación analítica de la dinámica inversa implementada en C++17 mediante la librería de encabezados `ur3e_dynamics.hpp`. Este módulo computa el algoritmo RNEA en un tiempo de ejecución determinista inferior a $50\mu s$, suministrando la base de par necesaria para linealizar el comportamiento dinámico del robot. Asimismo, aloja el controlador clásico por par computado (`ComputedTorqueController`) que sirve como referencia (*baseline*) experimental.
- **Módulo 3 (M_3) – Inteligencia Artificial y Motor de Cuantización:** Abarca el ciclo de vida completo de la red neuronal compensadora: desde la arquitectura de perceptrón multicapa (MLP) diseñada y entrenada en PyTorch (42 entradas, capas densas intermedias de 256, 512, 256 y 128 neuronas con activaciones ReLU, y 6 salidas de par), hasta su exportación al formato estándar ONNX y su posterior cuantización dinámica post-entrenamiento (PTQ) a enteros de 8 bits (INT8) mediante `quantize_model.py`. Este módulo integra el plugin de control `NeuralTorqueController`, el cual aloja una sesión persistente de la API C++ de ONNX Runtime configurada en modo monohilo (`SetIntraOpNumThreads(1)`) para garantizar latencias de inferencia ultra bajas e invariantes.
- **Módulo 4 (M_4) – Supervisión, Telemetría y Adquisición:** Integra el software de generación de trayectorias aleatorias y deterministas con polinomios de quinto orden (`random_trajectory_generator.py`), el subsistema de registro de telemetría de alta frecuencia mediante `ros2 bag` en almacenamiento binario estructurado MCAP, y las rutinas de procesamiento y filtrado digital (`bag_to_csv.py`) basadas en el filtro de Savitzky-Golay para la estimación suave de velocidades y aceleraciones a partir de datos experimentales.

2.1.4. Propuestas solución

En la concepción mecatrónica del sistema se analizaron diversas alternativas tecnológicas tanto a nivel de componentes individuales como de integración global del sistema.

Alternativas por Componente

1. Entorno de Planta y Simulación (M_1):

- *Opción 1.1 (Simulación Cinemática en MATLAB)*: Entorno accesible para validar cinemática teórica, pero carente de dinámica multicuerpo realista y sin compatibilidad nativa con bucles de tiempo real en C++.
- *Opción 1.2 (CoppeliaSim con API Remota)*: Simulación física versátil, pero su comunicación basada en sockets TCP/IP externos induce fluctuaciones de latencia inaceptables para control a 500 Hz.
- *Opción 1.3 (Gazebo Harmonic con `gz_ros2_control`)*: Integración nativa con la pila de control de ROS 2 en memoria compartida, resolución de contactos y total paridad de interfaces con el robot físico real.

2. Estrategia de Control Dinámico (M_2):

- *Opción 2.1 (PID Articular Independiente Desacoplado)*: Sencillo de implementar, pero incapaz de compensar el fuerte acoplamiento inercial, los efectos de Coriolis y la gravedad a velocidades moderadas o altas.
- *Opción 2.2 (Control por Par Computado Analítico RNEA)*: Linealiza la dinámica en todo el espacio de trabajo; no obstante, es vulnerable a incertidumbres paramétricas, fricciones no modeladas y envejecimiento mecánico.
- *Opción 2.3 (Control Adaptable no Lineal Clásico)*: Requiere derivar y calcular en línea matrices de regresores analíticos sumamente costosas computacionalmente para 6 GDL.

3. Motor de Compensación Inteligente y Despliegue (M_3):

- *Opción 3.1 (Inferencia en Python mediante Nodos ROS)*: Inviabile para el lazo crítico de control debido a las interrupciones del recolector de basura (*Garbage Collector*) y el bloqueo global de intérprete (GIL), generando retardos estocásticos de decenas de milisegundos.
- *Opción 3.2 (Red Neuronal FP32 en C++)*: Despliegue en punto flotante tradicional; aunque determinista, demanda un mayor ancho de banda de memoria y mayor ocupación de caché de nivel 1 y 2.
- *Opción 3.3 (Red Neuronal Cuantizada a INT8 con ONNX Runtime C++)*: Inferencia en precisión fija de 8 bits con operaciones aritméticas vectorizadas, reduciendo el tamaño del modelo en un 74.4% y manteniendo una latencia determinista inferior a 300 μ s.

Propuestas de Solución Integrada del Sistema A partir del análisis de componentes y del propósito global del proyecto, se definieron tres propuestas de integración conceptual:

Propuesta A (Control Clásico Desacoplado en Entorno Estándar): Consiste en la implementación de controladores PID individuales por articulación ejecutados en una arquitectura computacional genérica. Las trayectorias se generan de manera trapezoidal y no se incorpora ningún tipo de compensación analítica ni neuronal. Representa el esquema industrial más elemental y sirve como límite inferior de comparación.

Propuesta B (Plataforma Neutra de Comparación Hardware – Microcontrolador vs. FPGA): Esta propuesta surge como la plataforma de evaluación hardware concebida para realizar una comparación científica neutra y cuantitativa entre el paradigma de control clásico y el control inteligente. En este esquema, el control clásico PID se implementa en un microcontrolador o procesador embebido convencional, mientras que la inferencia de la red neuronal se acelera en hardware dedicado dentro de una tarjeta FPGA (aprovechando el paralelismo espacial y operaciones aritméticas de enteros de bajo consumo). Esto permite medir objetivamente la latencia, el consumo de potencia eléctrica y la ocupación de recursos de silicio (LUTs, DSPs, memoria) bajo condiciones experimentales idénticas. Debido a que en la fase TT1 no se contaba con la planta física confirmada y la implementación directa en FPGA requería desviar recursos del modelado cinemático-dinámico, esta propuesta se establece formalmente como el marco experimental objetivo a consumir en la fase TT2.

Propuesta C (Arquitectura Híbrida Cuantizada en Sim-to-Real – Solución Seleccionada para TT1): Plantea una arquitectura híbrida mecatrónica desarrollada en ROS 2 Jazzy y C++17, donde el algoritmo analítico RNEA proporciona el término principal de par nominal τ_{RNEA} , y una red neuronal cuantizada a INT8 desplegada mediante ONNX Runtime monohilo suministra la compensación de dinámicas residuales τ_{NN} . Todo el bucle se ejecuta dentro del marco determinista `ros2.control` gobernando el gemelo digital del UR3e en Gazebo Harmonic, con trayectorias quínticas continuas (C^2) y telemetría en formato MCAP. Esta propuesta permite demostrar con rigor la viabilidad algorítmica, numérica y temporal en TT1, garantizando una transferencia directa (*Sim-to-Real*) al manipulador físico UR3e asegurado para TT2, previo a la instrumentación en la plataforma neutra.

2.1.5. Validación

La validación conceptual de la arquitectura mecatrónica seleccionada (Propuesta C) se sustenta en tres análisis analíticos y de ingeniería que confirman su viabilidad para cumplir los requerimientos antes de su despliegue físico en TT2:

1. **Análisis de Viabilidad y Desacoplamiento Dinámico:** La dinámica articular de un manipulador rígido de 6 GDL viene dada por:

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) + \tau_f(\dot{q}) = \tau \quad (25)$$

Al implementar la ley de par híbrida $\boldsymbol{\tau} = \boldsymbol{\tau}_{RNEA}(\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}}_d) + \boldsymbol{\tau}_{NN}(\mathbf{x})$, el término analítico $\boldsymbol{\tau}_{RNEA}$ cancela las no linealidades macroscópicas dominantes asociadas a la inercia nominal $\hat{\mathbf{M}}(\mathbf{q})$, fuerzas de Coriolis y centrífugas $\hat{\mathbf{C}}(\mathbf{q}, \dot{\mathbf{q}})$ y pares gravitacionales $\hat{\mathbf{g}}(\mathbf{q})$. La red neuronal únicamente tiene la tarea acotada de aproximar la función de dinámicas residuales:

$$\boldsymbol{\tau}_{NN}(\mathbf{x}) \approx \Delta \mathbf{M}(\mathbf{q}) \ddot{\mathbf{q}}_d + \Delta \mathbf{C}(\mathbf{q}, \dot{\mathbf{q}}) \dot{\mathbf{q}} + \Delta \mathbf{g}(\mathbf{q}) + \boldsymbol{\tau}_f(\dot{\mathbf{q}}) \quad (26)$$

Dado que las incertidumbres residuales $\Delta(\cdot)$ y la fricción $\boldsymbol{\tau}_f$ tienen cotas superiores estrictamente finitas en el espacio de trabajo acotado del robot, el término neuronal opera dentro de un dominio compacto, previniendo divergencias o inestabilidades numéricas en bucle cerrado.

2. **Presupuesto Temporal de Tiempo Real (*Timing Budget*):** Para una frecuencia de control objetivo de $f_s = 500$ Hz, el periodo máximo disponible por ciclo es $T_s = 2000 \mu s$. Las mediciones de perfilado temporal en C++ arrojan los siguientes tiempos de ejecución en CPU monohilo:

- Adquisición y lectura de interfaces `ros2_control`: $\approx 10 \mu s$.
- Cálculo dinámico analítico RNEA (`ur3e_dynamics.hpp`): $\approx 35 - 50 \mu s$.
- Normalización de 42 características con escaladores precalculados: $\approx 5 \mu s$.
- Inferencia de red neuronal cuantizada INT8 en ONNX Runtime: $\approx 150 - 280 \mu s$.
- Desnormalización, saturación física y escritura de comandos de par: $\approx 10 \mu s$.

El tiempo total de procesamiento en el método `update()` es inferior a $360 \mu s$, lo que representa menos del 18 % del presupuesto total de $2000 \mu s$. Esto certifica un margen de holgura temporal superior al 82 %, garantizando determinismo estricto y total ausencia de violaciones de tiempo límite (*deadline misses*).

3. **Preservación de Rango Dinámico en INT8:** Al aplicar normalización estándar con media cero y desviación unitaria (*z-score*) a las 42 entradas y 6 salidas en el pipeline de entrenamiento:

$$\tilde{x}_i = \frac{x_i - \mu_{x_i}}{\sigma_{x_i}}, \quad \forall i \in \{1, \dots, 42\} \quad (27)$$

las distribuciones estadísticas quedan concentradas en el intervalo $[-3, 3]$ con una probabilidad superior al 99,7 %. La cuantización dinámica uniforme a 8 bits provee $2^8 = 256$ niveles de discretización lineal, lo cual otorga una resolución efectiva por bit suficiente para representar los pares con un error de redondeo del orden de $10^{-3} \text{ N} \cdot \text{m}$, un valor varios órdenes de magnitud menor que la fricción estática de las articulaciones del UR3e.

2.1.6. Selección diseño conceptual

Para formalizar la toma de decisiones ingenieriles y determinar la idoneidad técnica de la arquitectura para la fase TT1, se empleó una matriz de selección conceptual de Pugh ponderada. En este método, los criterios de evaluación reflejan los factores críticos de éxito del proyecto (viabilidad analítica, precisión dinámica, eficiencia computacional y preparación para hardware real en TT2).

Se asignó un peso relativo normalizado ($w_i \in [0, 1]$ con $\sum w_i = 1,0$) a cada criterio en función de su criticidad mecatrónica. Como solución de referencia (*Datum*, con puntaje base 0), se seleccionó la ****Propuesta B (Plataforma Neutra / FPGA)****, dado que representa el marco comparativo ideal proyectado. Las alternativas se calificaron con una escala relativa: +2 (significativamente mejor que la referencia), +1 (mejor), 0 (equivalente), -1 (inferior) y -2 (significativamente inferior).

En la Tabla 4 se detallan los resultados de la evaluación conceptual.

Cuadro 4: Matriz de selección conceptual de Pugh para las alternativas del sistema de control.

Criterio de Evaluación	Peso (w_i)	Propuesta A (PID Clásico)	Propuesta B (Plat. Neutra)	Propuesta C (Híbrida INT8)
1. Viabilidad de validación algorítmica y desriesgo previo en TT1	0.25	0	0 (Datum)	+2
2. Paridad y facilidad de transferencia al robot físico UR3e (TT2)	0.20	0	0 (Datum)	+2
3. Precisión de seguimiento ante dinámicas no lineales y fricción	0.20	-2	0 (Datum)	+1
4. Eficiencia de cómputo y reducción de huella de memoria (INT8)	0.15	+1	0 (Datum)	+1
5. Determinismo temporal y estabilidad en bucle cerrado	0.10	0	0 (Datum)	+1
6. Simplicidad de desarrollo e integración en fase TT1	0.10	+1	0 (Datum)	+1
Puntaje Total Ponderado ($\sum w_i s_i$)	1.00	-0.20	0.00	+1.45

Justificación de la Selección: Como se aprecia en la matriz de Pugh, la **Propuesta C (Arquitectura Híbrida Cuantizada en Sim-to-Real)** obtiene la calificación más alta (+1.45), superando de manera contundente tanto al PID clásico (-0.20) como a la línea base de la Propuesta B (0.00).

Las razones técnicas determinantes para esta elección en la fase TT1 radican en:

1. **Desriesgo y Viabilidad Integral:** Permite validar matemáticamente y mediante software determinista todo el pipeline de control híbrido (RNEA + Red Cuantizada en INT8) sobre el gemelo digital en simulación antes de comprometer hardware físico.
2. **Transferencia Directa a la Planta Robótica Física:** Dado que ya se cuenta con la planta física real asegurada para TT2, el diseño basado en el ecosistema estándar `ros2_control` garantiza que la migración desde la simulación hacia el manipulador UR3e físico no demandará reescribir la lógica de control, sino únicamente apuntar el archivo de configuración al driver oficial del robot (`Universal_Robots_ROS2_Driver`).
3. **Cimiento Sólido para el Benchmarking en TT2:** Al completar y consolidar la viabilidad de la red neuronal cuantizada y del algoritmo RNEA en TT1, el proyecto dispondrá en TT2 de un modelo completamente validado y calibrado para desplegarse en la plataforma de hardware neutra (Microcontrolador vs. FPGA), logrando una comparativa experimental rigurosa y libre de incertidumbres algorítmicas.

2.2. Diseño detallado

2.2.1. Detalle módulo 1 (M_1)

Validación (M_1)

2.2.2. Detalle módulo 2 (M_2)

Validación (M_2)

2.2.3. Detalle módulo n (M_n)

Validación (M_n)

2.2.4. Integración sistema mecatrónico

Validación sistema mecatrónico

3. Implementación del sistema

3.1. Implementación módulo 1 (M_1)

3.1.1. Verificación (M_1)

3.2. Implementación módulo 2 (M_2)

3.2.1. Verificación (M_2)

3.3. Implementación módulo n (M_n)

3.3.1. Verificación (M_n)

3.4. Integración del sistema mecatrónico

3.4.1. Verificación del sistema mecatrónico

4. Análisis de resultados

4.1. Análisis de ingeniería

4.2. Análisis de costos

4.3. Análisis de valor

Conclusiones

Recomendaciones y trabajo a futuro

Apéndices

Anexos

La gestión adecuada de los recursos y una planificación clara de las actividades son cruciales para el éxito de este proyecto. A continuación, se presenta un desglose de los recursos humanos, materiales, económicos y la infraestructura necesaria, seguido de una planeación general de actividades.

4.3.1. Recursos Estimados e Infraestructura

4.3.2. Recursos Humanos

Los participantes en el proyecto y sus roles son los siguientes:

- **Desarrollador:** Mendoza Díaz Ramiro.
 - *Dedicación Estimada:* Aproximadamente 600 horas distribuidas en las fases TT1 y TT2.
 - *Área Principal STEM de Aporte:* Ingeniería (Mecatrónica).
 - *Otras Áreas STEM de Aporte:* Tecnología, Ciencias de la Computación.
- **Asesor Principal:** Dr. Jorge Alejandro Juárez Lora.
 - *Dedicación Estimada:* Aproximadamente 60 horas de asesoría.
 - *Área Principal STEM de Aporte:* Ingeniería (Electrónica/IA).
 - *Otras Áreas STEM de Aporte:* Ciencias de la Computación.

4.3.3. Recursos Materiales y Económicos

A continuación, se listan los recursos materiales y económicos estimados para el proyecto:

- **Plataforma Robótica (Módulo 1):**
 - *Recurso:* Robot manipulador.
 - *Cantidad:* 1.
 - *Costo Estimado (MXN):* \$5,000. - \$15,000.
 - *Fuente de Financiamiento:* Recursos Propios.
 - *Recurso (Opcional):* Componentes para interfaz hardware (si se conecta simulador a FPGA mediante una placa intermedia).
 - *Cantidad:* 1.
 - *Costo Estimado (MXN):* \$500 - \$1,000.
 - *Fuente de Financiamiento:* Recursos Propios.

■ **Plataforma FPGA (Módulo 2):**

- *Recurso:* Tarjeta de desarrollo FPGA (ej., Xilinx Nexys A7 o PYNQ-Z2).
- *Cantidad:* 1.
- *Costo Estimado (MXN):* \$3,000 - \$7,000.
- *Fuente de Financiamiento:* Recursos Propios o tarjeta prestada por el asesor.
- *Recurso:* Cables y accesorios para FPGA (JTAG, USB, etc.).
- *Cantidad:* Varios.
- *Costo Estimado (MXN):* \$500.
- *Fuente de Financiamiento:* Recursos Propios.

■ **PC para Desarrollo (Módulo 3):**

- *Recurso:* Computadora personal para desarrollo (existente).
- *Cantidad:* 1.
- *Costo Estimado (MXN):* N/A (equipo existente).
- *Fuente de Financiamiento:* N/A.
- *Recurso:* Software de desarrollo (Xilinx Vivado, Python, TensorFlow/PyTorch, CoppeliaSim).
- *Cantidad:* Licencias o descargas.
- *Costo Estimado (MXN):* N/A (se priorizará software gratuito, con licencia educativa o ya disponible).
- *Fuente de Financiamiento:* N/A.

■ **Material Diverso y Consumibles (Módulo 4):**

- *Recurso:* Componentes electrónicos menores (resistencias, cables, protoboard, si se construye alguna interfaz simple).
- *Cantidad:* Varios.
- *Costo Estimado (MXN):* \$300.
- *Fuente de Financiamiento:* Recursos Propios.
- *Recurso:* Material de impresión y papelería (para documentación, artículos).
- *Cantidad:* Según necesidad.
- *Costo Estimado (MXN):* \$200.
- *Fuente de Financiamiento:* Recursos Propios.

■ **Imprevistos:**

- *Descripción:* Reserva para gastos no contemplados (aproximadamente 10 % del subtotal de gastos directos).

- *Costo Estimado (MXN)*: A definir una vez se tengan costos más precisos.
- *Fuente de Financiamiento*: Recursos Propios.

Nota: Los costos son estimaciones preliminares. Las necesidades y costos pueden variar a medida de que avanza el proyecto.

4.3.4. Infraestructura Requerida

La infraestructura necesaria para el proyecto incluye:

■ Instalaciones Físicas:

- Laboratorio de Cómputo de UPIITA: Para acceso a software especializado y desarrollo general.
- Espacio de Trabajo Personal: Para desarrollo y estudio.
- (Opcional) Laboratorio de Sistemas digitales de UPIITA: Si se requiere para pruebas con un robot físico, construcción de interfaces, o mediciones energéticas.

■ Equipo Principal:

- Computadora Personal (PC personal).
- Tarjeta de Desarrollo FPGA: Puede ser la Digilent Nexys 3 de los laboratorios de electronica de UPIITA, Intesc amiba 2 propia, o la proporcionada por el asesor.
- Robot Manipulador Físico: Pueden ser modelos desde 4 hasta 6 grados de libertad disponibles en el mercado que se ajusten al presupuesto o el proporcionado por el asesor.
- Instrumentación Electrónica: Multímetro, osciloscopio, fuente de alimentación regulada.

■ Software Especializado:

- Entorno de Desarrollo Integrado (IDE) para FPGA: Xilinx Vivado Design Suite (se utilizará la versión WebPACK gratuita o la disponible bajo licencia académica en UPIITA).
- Lenguajes de Programación: Python (versión 3.8 o superior), VHDL o Verilog (según la preferencia para el diseño en FPGA).
- Frameworks de Deep Learning: TensorFlow (versión 2.x con TensorFlow Lite) y/o PyTorch (con su módulo de cuantización).
- Simulador Robótico: CoppeliaSim (V-REP) en su versión educativa (gratuita).
- Software de Productividad: Un editor de LaTeX como overleaf, un gestor de referencias bibliográficas, software para creación de diagramas.
- Sistema de Control de Versiones: Git, con un repositorio en GitHub o GitLab.

4.3.5. Planeación de Actividades (Cronograma General)

La gestión detallada del proyecto, incluyendo la asignación de tareas específicas y el seguimiento del progreso, se realizará mediante *Sprints* de duración definida (ej., 2 a 4 semanas), conforme a la metodología *Scrum* adoptada (ver Sección 1.2.1). Para fines de este protocolo, se presenta a continuación una planeación general de alto nivel, distribuyendo los Épicos del proyecto a lo largo de las 36 semanas estimadas (18 semanas para Trabajo Terminal 1 - TT1, y 18 semanas para Trabajo Terminal 2 - TT2).

Fase TT1 (Semanas 1-18): Enfoque en Investigación, Diseño y Desarrollos Preliminares

■ *Semanas 1-4:*

EP01 Configuración del Entorno de Desarrollo y Simulación Robótica (CoppeliaSim, Python, interfaz básica).

INV01 Investigación exhaustiva del estado del arte: QNNs, control robótico, FPGAs, metodologías de evaluación energética.

DOC1 Inicio de la documentación de avances.

■ *Semanas 5-8:*

EP03 Diseño conceptual de la arquitectura de Red Neuronal (FP12-NN) para control. Generación/adquisición de datos de entrenamiento.

EP02 Diseño conceptual del controlador PID y su adaptación para FPGA.

DOC1 Continuación de la documentación.

■ *Semanas 9-13:*

EP03 Entrenamiento y validación (simulación Python) del modelo FP12-NN.

EP02 Inicio del desarrollo HDL y simulación del controlador PID para FPGA.

EP05 Investigación detallada y selección de técnicas y herramientas de cuantización.

DOC1 Continuación de la documentación.

■ *Semanas 14-18:*

EP02 Finalización de la implementación y pruebas básicas del PID en FPGA (interactuando con robot simulado).

EP05 Aplicación preliminar de cuantización (PTQ) al modelo FP12-NN para generar un primer QNN (ej., INT6).

DOC1 Preparación y finalización del informe de avances TT1.

ENT1 Entrega y presentación de avances TT1.

Fase TT2 (Semanas 19-36): Enfoque en Implementación en FPGA, Experimentación y Análisis

■ *Semanas 19-22:*

EP04 Diseño HDL e implementación del controlador FP12-NN en FPGA. Simulación y pruebas.

EP05/EP06 Refinamiento de la cuantización (posible QAT) y diseño HDL de los controladores QNN (INT6, INT4).

DOC2 Inicio de la redacción de la tesis con toda la documentación previa.

■ *Semanas 23-26:*

EP06 Implementación y pruebas en FPGA de los controladores QNN.

EP07 Diseño e implementación del sistema de medición/estimación de consumo energético y uso de recursos en la FPGA.

DOC2 Avance en la tesis.

■ *Semanas 27-31:*

EP08 Diseño e implementación del sistema de medición del rendimiento del control (precisión, latencia) en la FPGA.

EP09 Desarrollo de la interfaz de orquestación de pruebas y recolección de datos (PC - FPGA).

EP10 Inicio de la ejecución de experimentos comparativos.

DOC2 Continuación de la tesis.

■ *Semanas 32-36:*

EP10 Finalización de los experimentos. Análisis estadístico e interpretación de todos los resultados comparativos.

DOC2 Redacción final de la tesis, incluyendo conclusiones y trabajo futuro.

ENT2 Entrega de la tesis y preparación para la presentación final.

Nota: Este cronograma es una guía general de alto nivel. La asignación específica de tareas a los Sprints y su duración se definirá dinámicamente durante el proyecto, facilitando la adaptación a los hallazgos y desafíos que surjan. INV01, DOC1, DOC2, ENT1 y ENT2 son hitos o actividades transversales.

Fuentes – Referencias

Referencias

- [1] R. Eigenmann and D. J. Lilja, “Von neumann computers,” January 1998, purdue University / University of Minnesota.
- [2] All About Circuits. (2022, March) Neural network quantization: What is it and how does it relate to tiny machine learning? Accessed: 2025-05-10. [Online]. Available: <https://www.allaboutcircuits.com/technical-articles/neural-network-quantization-what-is-it-and-how-does-it-relate-to-tiny-machine-learning/>
- [3] Wattco. (2024, julio) Controlador pid explicado: tipos, usos y operaciones. Accessed: 2025-05-01. [Online]. Available: <https://www.wattco.com/es/2024/07/controlador-pid-explicado/>
- [4] P. N. H. (2024, October) Artificial neural networks (anns) and their role in machine learning. Accessed: 2025-05-12. [Online]. Available: <https://medium.com/@prasanNH/artificial-neural-networks-anns-and-their-role-in-machine-learning-e19a214e46ec>
- [5] Q. Jaffery. (2023, September) Ann vs dnn. Accessed: 2025-05-12. [Online]. Available: <https://www.linkedin.com/pulse/ann-vs-dnn-qasim-jaffery/>
- [6] F. C. P. Kevin M. Lynch, *Modern robotics*. Reino Unido: Cambridge University Press, 2017.
- [7] J. A. J. Lora, “Design and implementation of a neuromorphic processing platform for robotic control systems,” Tesis de Doctorado en Ciencias de la Computación, Centro de Investigación en Computación, Instituto Politécnico Nacional, Ciudad de México, diciembre 2024.
- [8] Y. Park, J. Lee, D. Sim, Y. Cho, and C. Park, “Designing spiking neural network-based reinforcement learning for 3d robotic arm applications,” *Electronics*, vol. 14, no. 3, p. 578, 2025, article number 578. Check year if accessing preprint vs final version.
- [9] J. Chen, J. Li, Y. Li, and X. Miao, “Multiply accumulate operations in memristor crossbar arrays for analog computing,” *Journal of Semiconductors*, vol. 42, no. 1, p. 013104, 2021.
- [10] T. Liang, J. Glossner, L. Wang, S. Shi, and X. Zhang, “Pruning and quantization for deep neural network acceleration: A survey,” *Neurocomputing*, vol. 461, pp. 370–403, 2021.
- [11] C. Bartolozzi, G. Indiveri, and E. Donati, “Embodied neuromorphic intelligence,” *Nature Communications*, vol. 13, p. 1024, 2022.

- [12] A. de Vries-Gao, “Artificial intelligence: Supply chain constraints and energy implications,” *Joule*, vol. 9, pp. 1–4, may 2025, published April 10, 2025.
- [13] L. Zhang, X. Hu, X. Liao, T. Zhou, Y. Peng, and Q. Zhao, “FLQ: Design and implementation of hybrid multi-base full logarithmic quantization neural network acceleration architecture based on FPGA,” *Signal Processing: Image Communication*, vol. 134, p. 117270, 2025, available online 16 January 2025.
- [14] I. I. Arikpo, F. U. Ogban, and I. E. Eteng, “VON NEUMANN ARCHITECTURE AND MODERN COMPUTERS,” *GLOBAL JOURNAL OF MATHEMATICAL SCIENCES*, vol. 6, no. 2, pp. 97–103, 2007.
- [15] Álvaro Domingo Reguero, S. Martínez-Fernández, and R. Verdecchia, “Energy-efficient neural network training through runtime layer freezing, model quantization, and early stopping,” *Computer Standards & Interfaces*, vol. 92, p. 103906, 2025, published online 10 October 2024.
- [16] Y. Zhang, B. Yin, M. D. Gomony, H. Corporaal, C. Trinitis, and F. Corradi, “Hardware/software co-design optimization for training recurrent neural networks at the edge,” *Journal of Low Power Electronics and Applications*, vol. 15, no. 1, p. 15, 2025, article number 15. Check year if accessing preprint vs final version.
- [17] B. Jiang, J. Chen, and Y. Liu, “Single-shot pruning and quantization for hardware-friendly neural network acceleration,” *Engineering Applications of Artificial Intelligence*, vol. 126, p. 106816, 2023.
- [18] Y. S. Lee, Y.-H. Gong, S. W. Chung, Y. Kim, and E. Lim, “Scale-CIM: Precision-scalable computing-in-memory for energy-efficient quantized neural networks,” *Journal of Systems Architecture*, vol. 134, p. 102787, 2023, available online 30 November 2022.
- [19] K. M. Lynch and F. C. Park, “Robot control,” in *Modern Robotics*, L. Miller and K. Roberts, Eds. Berlin: Cambridge University Press, 2017, pp. 434–437.
- [20] L. Zanatta, F. Barchi, S. Manoni, S. Tolu, A. Bartolini, and A. Acquaviva, “Exploring spiking neural networks for deep reinforcement learning in robotic tasks,” *Scientific Reports*, vol. 14, p. 30648, 2024, article number 30648. Published online: 28 December 2024. Check year if different in final print.
- [21] D. Kudithipudi, C. Schuman, C. M. Vineyard, T. Pandit, C. Merkel, R. Kubendran, J. B. Aimone, G. Orchard, C. Mayr, R. Benosman, J. Hays, C. Young, C. Bartolozzi, A. Majumdar, S. G. Cardwell, M. Payvand, S. Buckley, S. Kulkarni, H. A. Gonzalez, G. Cauwenberghs, C. S. Thakur, A. Subramoney, and S. Furber, “Neuromorphic computing at scale,” *Nature*, vol. 637, pp. 801–812, 2025, published online: 22 January 2025. Check year if accessing preprint vs final version.
- [22] A. Mehonic and A. J. Kenyon, “Brain-inspired computing needs a master plan,” *Nature*, vol. 604, no. 7905, pp. 255–260, 2022.

- [23] W. Maass, “Networks of spiking neurons: The third generation of neural network models,” *Neural Networks*, vol. 10, no. 9, pp. 1659–1671, 1997.
- [24] D. Vlasov, A. Minnekhanov, R. Rybka, Y. Davydov, A. Sboev, A. Serenko, A. Ilyasov, and V. Demin, “Memristor-based spiking neural network with online reinforcement learning,” *Neural Networks*, vol. 166, pp. 512–523, 2023.
- [25] M. V. Mark W. Spong, Seth Hutchinson, *Robot Modeling and Control*. Estados Unido: Wiley, 2005.
- [26] Intel. (2021) Llevar la computación neuromórfica al siguiente nivel con loihi 2. Accessed: 2025-05-01. [Online]. Available: <https://www.intel.la/content/www/xl/es/research/neuromorphic-computing-loihi-2-technology-brief.html>
- [27] X. Li, H. Jiang, R. Zhang, F. Tian, S. Huang, and D. Xu, “Robustness-aware 2-bit quantization with real-time performance for neural network,” *Neurocomputing*, vol. 455, pp. 12–22, 2021.
- [28] N. M. Rezk, T. Nordström, D. Stathis, Z. Ul-Abdin, E. E. Aksoy, and A. Heman, “MOHAQ: Multi-Objective Hardware-Aware quantization of recurrent neural networks,” *Journal of Systems Architecture*, vol. 133, p. 102778, dec 2022.
- [29] K. Schwaber and J. Sutherland, *The Scrum Guide™*, November 2020, the Definitive Guide to Scrum: The Rules of the Game. Available at <https://scrumguides.org>. [Online]. Available: <https://scrumguides.org>
- [30] E. L. Cano, J. M. García-Camús, J. Garzás, J. M. Moguerza, and N. N. Sánchez, “A scrum-based framework for new product development in the non-software industry,” *Journal of Engineering and Technology Management*, vol. 61, p. 101634, 2021. [Online]. Available: <https://doi.org/10.1016/j.jengtecman.2021.101634>

Glosario